國立中興大學資訊管理學系

碩士學位論文

基於集成深度學習模型之多角度多序列核磁共振影像腦部腫瘤自動化診斷研究

Automated Brain Tumor Diagnosis from Multi-Angle and Multi-Sequence MRI Using Ensemble Deep Learning Models

指導教授：蔡孟勳 博士 Meng-Hsiun Tsai Ph.D.

研究生：蔡宏昱 Hung-Yu Tsai

中華民國一百一十四年八月

國立中興大學資訊管理學系(所)

碩士學位論文

題目：基於集成深度學習模型之多角度多序列核磁共振影像腦部腫瘤自動化診斷研究

姓名：蔡宏昱　　學號：7112029043

經 口 試 通 過 特 此 證 明

論文指導教授 [signature]

論文考試委員 [signature]

[signature]

[signature]

中華民國 114 年 7 月 14 日

誌謝辭

首先，在這兩年的實驗室生涯當中，我要誠摯感謝我的指導教授蔡孟勳教授，感謝老師在學業與研究上提供我細心的指導與寶貴的建議。老師對我們的信任，讓我有機會參與許多重要的任務，這些經驗對我而言極為珍貴，亦是我學習歷程中難能可貴的一部分。

感謝口試委員陳牧言教授與鄭文郁教授，撥冗審閱本篇論文，並提出許多寶貴的意見，讓論文內容能更加充實與完整。

感謝實驗室的學長姐們—晏彰、浩章、忠廷、盈甄、昀昕、忠勳與芊芊，感謝你們無私地傳授實驗室的經驗與技巧，並在我遇到困難時給予我指導與協助，讓我能夠順利成長與適應實驗室的節奏。

感謝實驗室的同儕—宗偉、承鴻、凱揚、冠甫與欣樺，我們一同經歷了無數挑戰與回憶，不論是輕鬆的歡聚時光，或是攜手完成實驗任務的努力過程，這段相伴的歲月對我而言都是無可取代的寶藏。

感謝實驗室的學弟妹們—浩恩、智祥、怡之、子珊、晏羽與子芩，有你們的加入為實驗室注入了嶄新的活力，也帶來了無數歡笑。透過指導與協助你們的過程，我也重新省視並學習了許多，受益良多。

感謝實驗室的凱程學長與宇紘學長，於每次實驗室開會時總是耐心地給予我細心指導，無論在研究方向的釐清、論文撰寫的建議，或是實作細節上的分享，都讓我獲益良多。

特別感謝台中榮民總醫院的鄭文郁醫師、楊志展醫師以及怡津學姊，提供本研究所需的影像資料，並在醫學專業知識方面給予我細心的指導，使本研究能夠具備正確性與完整性。

最後，衷心感謝我的父母，在精神上與經濟上始終給予我最堅定的支持，讓我能夠無後顧之憂地完成學業。也要感謝我的外婆、舅舅、哥哥與阿姨們，在求學過程中給予我滿滿的鼓勵與關懷，使我始終懷抱著前進的勇氣與信心。

蔡宏昱

國立中興大學資訊管理學系

中華民國一百一十四年八月八日

摘要

腦部腫瘤為神經系統中常見且具高複雜度的疾病，臨床診斷高度仰賴核磁共振影像的判讀。然而，由於腦瘤類型多樣、影像表現具異質性，且部分病灶邊界模糊，醫師需耗費大量時間進行解讀，且診斷結果易受主觀經驗影響，導致一致性與效率不足。隨著人工智慧與深度學習技術的快速發展，建立自動化、可解釋的腦瘤診斷模型已成為重要研究方向。本研究旨在開發一套結合多角度（axial、sagittal、coronal）與多序列（T1、T2、FLAIR）核磁共振影像的腦部腫瘤自動化診斷系統，並藉由集成多種深度學習模型，以提升分類與分割任務的準確性與穩定性。影像資料來自臺中榮總，涵蓋膠質母細胞瘤、腦膜瘤、腦下垂體瘤與正常腦影像共四類，經標註後轉換為語意遮罩與 YOLO 所需格式座標，並實施旋轉、亮度調整與導引濾波等資料增量處理，以增強模型泛化能力。在影像分類任務方面，本研究比較 ResNet50、EfficientNet、ResNeSt50d 、EfficientNetV2、Swin Transformer、Vision Transformer、Efficient Transformer 和 Pooling-based Vision Transformer 八種模型，並透過集成學習整合最佳模型之預測結果。結果顯示，ResNet50 於分類準確率與 F1-score 表現最佳，而 ResNeSt50d 於召回率與 AUC 上具優勢。在集成方法中，Stacking 在整體效能上最穩定，準確率可達 94.41%。同時，透過 Grad-CAM 視覺化工具對模型可解釋性進行分析，顯示分類模型多聚焦於腫瘤區域，具備臨床可信度。於影像分割任務中，採用 YOLOv8、YOLOv11、Swin-Unet 與 Mask R-CNN 四種模型進行遮罩預測，其中 YOLOv8 表現最為優異，達成 Precision 99.20%、Recall 95.80%、IoU 0.8980 與 Dice 0.9443，能有效辨識腫瘤邊界與形狀。綜上所述，本研究建構之深度學習診斷流程整合了多模態影像、資料增量技術與集成學習策略，能有效提升核磁共振影像中腦瘤之自動分類與遮罩分割效能，並具備可解釋性與即時性，具備實際臨床應用潛力。未來可朝三維核磁共振影像、多機構資料泛化、半監督學習與模型輕量化部署等方向進行延伸，進一步推動智慧醫療診斷輔助系統之發展。

關鍵字：深度學習、核磁共振、集成學習、膠質母細胞瘤、腦膜瘤、腦下垂體瘤

Abstract

Brain tumors are common and complex diseases of the nervous system, with clinical diagnosis highly dependent on the interpretation of magnetic resonance imaging (MRI). However, the diversity of tumor types, heterogeneous imaging characteristics, and blurred lesion boundaries often make diagnosis time-consuming and heavily reliant on physicians' subjective experience, resulting in inconsistent and inefficient outcomes. With the rapid advancement of artificial intelligence and deep learning technologies, the development of automated and interpretable diagnostic models for brain tumors has become a critical research direction.This study proposes an automated brain tumor diagnosis system that integrates multi-angle (axial, sagittal, coronal) and multi-sequence (T1, T2, FLAIR) MRI images, aiming to enhance the accuracy and robustness of classification and segmentation tasks through ensemble deep learning models. The dataset, provided by Taichung Veterans General Hospital, includes four categories: glioblastoma, meningioma, pituitary adenoma, and normal brain images. All images were annotated and converted into semantic masks and YOLO-format labels. Data augmentation techniques, such as image rotation, brightness adjustment, and guided filtering, were applied to improve model generalization.In the tumor classification task, this study conducted a comparative evaluation of eight deep learning models: ResNet50, EfficientNet, ResNeSt50d, EfficientNetV2, Swin Transformer, Vision Transformer, EfficientFormer, and Pooling-based Vision Transformer. Among them, ResNet50 exhibited the highest performance in terms of classification accuracy and F1-score, whereas ResNeSt50d outperformed others in recall and AUC. Regarding ensemble strategies, the Stacking method demonstrated the most consistent and robust overall performance, achieving an accuracy of up to 94.41%. Additionally, Grad-CAM was employed to assess model interpretability, revealing that the classification models primarily attended to tumor regions, thereby reinforcing their clinical relevance and reliability.For tumor segmentation, four models were compared: YOLOv8, YOLOv11, Swin-Unet, and Mask R-CNN. Among them, YOLOv8 showed the best overall performance, achieving a precision of 99.20%, recall of 95.80%, IoU of 0.8980, and Dice score of 0.9443, indicating its strong capability in delineating tumor boundaries and shapes.In conclusion, the proposed diagnostic framework, which integrates multi-modal imaging, data augmentation, and ensemble deep learning techniques, effectively enhances the performance of automatic tumor classification and segmentation on MRI images. The system demonstrates interpretability and real-time applicability, making it suitable for practical clinical deployment. Future research may explore 3D MRI, multi-center datasets, semi-supervised learning, and model lightweighting to further advance intelligent medical

diagnostic systems.

Keywords: Deep Learning, Magnetic Resonance Imaging, Ensemble Learning, Glioblastoma, Meningioma, Pituitary Adenoma

目次

摘要 i

Abstract ii

目次 iv

表目次 vii

圖目次 viii

第 1 章　緒論 1

1.1　研究背景與動機 1

1.2　研究目的 2

1.3　研究架構 3

第 2 章　文獻探討 4

2.1　腦腫瘤相關疾病 4

2.1.1　腦膜瘤 5

2.1.2　腦下垂體瘤 5

2.1.3　膠質母細胞瘤 6

2.2　醫學影像在腦部腫瘤診斷之應用 8

2.3　基於深度學習之腦部腫瘤診斷應用 9

2.3.1　卷積神經網路(Convolutional Neural Network) 9

2.3.2　Transformer 10

2.3.3　CNN 結合 Transformer 12

2.4　基於深度學習之腦部腫瘤分割應用 13

2.4.1　語意分割 13

2.4.2　實例分割 14

第 3 章　研究方法 16

3.1 資料集介紹 17
3.2 資料預處理 19
3.3 資料標註 21
3.4 資料增量 23
3.5 影像分類模型架構 25
3.5.1 純 CNN 架構 26
3.5.2 純 Transformer 架構 30
3.5.3 CNN 與 Transformer 混合型架構 35
3.6 集成學習方法 36
3.6.1 投票法（Voting） 36
3.6.2 疊加法（Stacking） 37
3.7 影像分割模型架構 38
3.7.1 YOLO 39
3.7.2 Swin-Unet 42
3.7.3 Mask R-CNN 43
3.8 模型驗證與評估指標 44
3.8.1 影像分類結果評估 44
3.8.2 影像分割結果評估 47
3.9 圖形化使用者介面設計 49
第 4 章 實驗結果與討論 50
4.1 實驗流程 50
4.2 實驗環境配置與模型訓練參數 51
4.3 影像分類模型結果比較 53
4.3.1 模型訓練結果比較 53

4.3.2 分類模型可解釋性分析 55
4.4 集成學習分類結果比較 58
4.5 影像分割模型結果比較 59
4.6 圖形化介面展示與操作結果 64
4.7 實驗結果探討 65
第 5 章 結論與未來展望 66
5.1 結論 66
5.2 未來展望 67
參考文獻 68

表目次

表 3.1 資料篩選前後數量表 19
表 3.2 影像序列分布表 19
表 3.3 影像軸向分布表 19
表 4.1 實驗環境配置表 51
表 4.2 分類模型參數配置表 52
表 4.3 影像分割模型參數配置表 52
表 4.4 增量前分類模型結果比較表 53
表 4.5 增量後分類模型結果比較表 54
表 4.6 ResNet 模型 Grad-CAM 表 55
表 4.7 ResNeSt 模型 Grad-CAM 表 56
表 4.8 EfficientNetV2 模型 Grad-CAM 表 57
表 4.9 集成學習方法結果比較表 58
表 4.10 增量前分割效果比較表 59
表 4.11 增量後分割效果比較表 60
表 4.12 膠質母細胞瘤影像分割模型分割結果比較表 61
表 4.13 腦膜瘤影像分割模型分割結果比較表 62
表 4.14 腦下垂體瘤影像分割模型分割結果比較表 63

圖目次

圖 1.1 研究架構圖 3
圖 3.1 研究流程圖 16
圖 3.2 膠質母細胞瘤 MRI 影像 17
圖 3.3 腦膜瘤病患 MRI 影像 17
圖 3.4 腦下垂體瘤病患 MRI 影像 17
圖 3.5 無腫瘤 MRI 影像 17
圖 3.6 Axial 橫斷面影像示意圖 18
圖 3.7 Sagittal 矢狀面影像示意圖 18
圖 3.8 Coronal 冠狀面影像示意圖 18
圖 3.9 T1 影像示意圖 18
圖 3.10 T2 影像示意圖 18
圖 3.11 Flair 影像示意圖 18
圖 3.12 LabelMe 標註操作示意圖 21
圖 3.13 各類別腫瘤原始 MRI 與 Semantic Mask 示意圖 22
圖 3.14 原始影像 24
圖 3.15 亮度降低後影像 24
圖 3.16 亮度提高後影像 24
圖 3.17 對比拉伸後影像 24
圖 3.18 水平翻轉後影像 24
圖 3.19 小角度旋轉後影像 24
圖 3.20 導引濾波後影像 24
圖 3.21 ResNet 殘差單元示意圖 26
圖 3.22 EfficientNet-B0 架構示意圖 27

圖 3.23 ResNeSt 單元架構示意圖 28
圖 3.24 Vision Transformer 模型架構示意圖 30
圖 3.25 Swin Transformer V2 模型架構示意圖 32
圖 3.26 EfficientFormer 模型架構示意圖 34
圖 3.27 PiT 模型架構示意圖 35
圖 3.28 YOLO 原始架構示意圖 39
圖 3.29 YOLOv8 模型架構圖 40
圖 3.30 Swin-Unet 模型架構圖 42
圖 3.31 Mask R-CNN 模型架構示意圖 43
圖 3.32 混淆矩陣 44
圖 3.33 AUC 比較示意圖 46
圖 3.34 IoU 示意圖 48
圖 3.35 DSC 示意圖 48
圖 4.1 實驗流程圖 50
圖 4.2 GUI 介面影像上傳示意圖 64
圖 4.3 介面診斷預測結果示意圖 64

第 1 章　緒論

1.1 研究背景與動機

腦部腫瘤為神經系統中重要且複雜的疾病類別，其臨床診斷與治療決策高度仰賴高品質的影像資料與專業醫師的判讀經驗。常見腦瘤如膠質母細胞瘤（Glioblastoma）、腦膜瘤（Meningioma）、腦下垂體腺瘤（Pituitary Adenoma）等，分別具有不同的生物特性、影像表現與預後風險。早期正確辨識與精確定位腫瘤區域對於提高治療成效與延長病患存活時間具有關鍵影響，實現人民健康平權與永續照護[1, 2]。

根據衛生福利部統計資料，民國 111 年臺灣腦部惡性腫瘤發生個案數佔全部惡性腫瘤發生個案數的 0.56%，死亡人數則佔所有惡性腫瘤死亡的 0.61%。腦部惡性腫瘤在男性惡性腫瘤死亡原因中排名第 13 位，在女性中則為第 12 位，顯示其雖非最常見癌別，但仍具有一定的致死率與臨床挑戰性[3]。

根據美國中樞神經腫瘤登記中心（Central Brain Tumor Registry of the United States, CBTRUS）統計，每年原發性腦部與中樞神經系統腫瘤的整體發生率約為每十萬人口 25.34 例，當中涵蓋惡性與良性腫瘤。進一步分析顯示，惡性腦腫瘤的年發生率為 6.89/100,000，約佔全部腦瘤個案的 27.2%，而良性腦腫瘤的發生率則達 18.46/100,000，占比達 72.8%。雖然臨床與研究領域多聚焦於惡性腫瘤的預後與治療策略，然而良性腦瘤在整體病例中其實佔據多數，且常因腫瘤生長位置導致顯著神經學症狀與功能損傷，對患者的生活品質與長期照護需求構成挑戰，故其臨床關注價值亦不容忽視[4]。

其中，膠質母細胞瘤為最常見且最具侵襲性的腦部惡性腫瘤之一，具高度惡性與快速進展特性，預後極差，是目前治療難度最高的中樞神經系統腫瘤[5]。腦膜瘤雖多為良性，惟其可能因壓迫重要腦神經結構導致嚴重神經功能障礙，亦不容忽視[6]。至於腦下垂體瘤則常位於腦中線附近之蝶鞍區，雖多屬良性腫瘤，但因其鄰近視神經與下視丘，易引發內分泌失調或視力障礙，影響病患生活品質甚鉅[7]。這些腦瘤類型各具臨床挑戰性，亦為神經影像診斷與腫瘤分類研究的重要對象。

核磁共振影像（Magnetic Resonance Imaging, MRI）因其具備高解析度、無輻射與多模態特性，已成為腦瘤臨床診斷的首選工具。尤其透過多序列（T1、T2、FLAIR）與多視角（axial、coronal、sagittal）影像，可從不同層面呈現病灶的形態與異質性[8]。然而，在實務上 MRI 影像判讀需耗費大量醫師時間與精力，且不同醫師間的主觀差異可能導致診斷結果不一致[9]。此外，對於醫學影像資料量大且影像品質不一與腫瘤邊界模糊的情況，傳統人工分析亦容易出現誤判或遺漏[10]。

隨著人工智慧與深度學習技術的快速發展，特別是在影像分類與分割任務中展現優異表現，醫學影像自動化分析逐漸成為研究與臨床應用的重要方向。透過深度神經網路自動學習影像特徵，可有效降低人為判讀負擔、提升診斷效率與準確性。過往研究已證實卷積神經網路與 Transformer 架構皆可勝任於腦瘤影像的分類與分割任務，但是在臨床落地應用中仍存在如模型泛化能力不足、遮罩邊界精度不佳與分類模型缺乏解釋性等問題，尚待進一步改良[11-13]。

1.2 研究目的

隨著醫療影像與深度學習技術的發展，人工智慧逐漸被應用於腦部腫瘤診斷輔助中。然而，由於腦瘤類型多樣、影像異質性高，且部分病灶邊界不明，使得分割與分類仍具挑戰。為提升診斷效率與準確性，並減輕臨床人力負擔，本研究旨在建構一套結合多模態影像與自動化模型之分析流程。具體研究目的如下：

(1) 建構自動化的診斷流程可減少人工標註與影像判讀負擔，降低臨床人力耗用，並加快腫瘤檢測與分類速度，有助於提升診斷效率與醫療資源運用效益。

(2) 利用多角度與多序列影像之同步輸入，直接在同一模型中進行多模態訓練，以提高對不同掃描條件適應性與泛化性能。

(3) 比較傳統卷積神經網路（CNN）、 Transformer 與混合型架構在腦腫瘤分類任務上的表現，並探討集成學習策略對分類總體性能的提升效果。

(4) 應用可視化解釋技術揭示模型判斷依據，評估分類模型應用於真實診斷場景中的可靠性與實用性。

(5) 比較實例分割與語意分割方法在腦腫瘤區域分割精度與臨床可用性上的表現差異，以評估其在自動輔助診斷中的應用潛力。

1.3 研究架構

本研究共分為五章，依循由問題導入、理論建構、方法實作至結果驗證的研究流程；第一章為緒論，說明研究背景與動機、研究目的與整體研究架構；第二章為文獻探討，回顧腦腫瘤相關疾病、醫學影像於診斷應用之現況，以及深度學習於腦瘤分類與分割任務上的研究發展；第三章為研究方法，介紹資料來源與前處理流程，並說明所建構之分類模型、分割模型與集成學習方法；第四章為實驗結果與討論，依序呈現實驗流程與參數設置，並比較各模型在分類與分割任務中的表現；第五章為結論與未來展望，統整研究成果與限制，並提出後續研究建議。

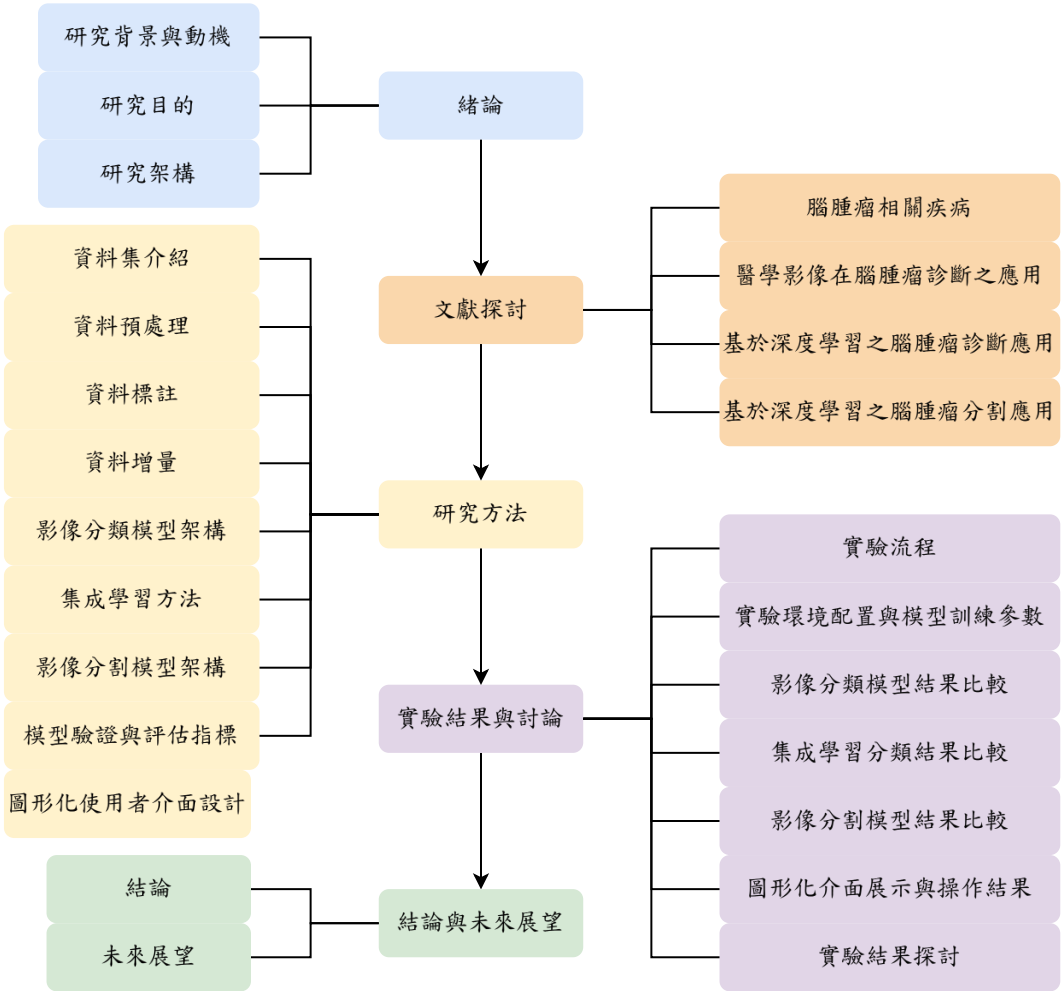


圖 1.1 研究架構圖

第 2 章　文獻探討

2.1 腦腫瘤相關疾病

腦部腫瘤依其來源可分為原發性與轉移性兩大類，其中原發性腫瘤可再依細胞來源區分為神經膠質瘤與非神經膠質瘤，包括起源自神經、血管、腺體等結構的腫瘤[14]。根據世界衛生組織（World Health Organization, WHO）對中樞神經系統腫瘤的分類標準，腦瘤可分為第一至第四級，其中第一級腫瘤通常為良性、具低增生潛力，預後相對良好；第四級則代表高度惡性，具有快速生長與侵襲特性，如膠質母細胞瘤（Glioblastoma, GBM）[14]。腦瘤的臨床表現多樣，主要取決於腫瘤的位置、大小、侵犯範圍以及是否造成腦水腫或顱內壓上升。常見症狀包括進行性頭痛、噁心與嘔吐、癲癇發作、視力異常、局部神經功能障礙、行為與性格改變等。若腫瘤位於腦幹或壓迫腦室系統，則可能快速引發意識障礙與腦疝等危及生命的狀況[15]。

臨床上，腦瘤的診斷依賴於影像學檢查與病理學評估。核磁共振（Magnetic Resonance Imaging, MRI）是首選的影像診斷工具，具高解析度且能評估腫瘤與周邊結構的關係，並可透過造影劑增強觀察血腦屏障破壞與腫瘤侵犯程度；電腦斷層掃描（Computed Tomography , CT）則可輔助評估顱內出血或骨質變化[15]。在手術或立體定位活檢取得組織後，病理切片與免疫組織化學染色可進一步確立診斷，並透過分子檢測釐清如 IDH、TERT、1p/19q 等關鍵基因突變，以輔助腫瘤分類與預後評估[14]。治療方面，腦瘤的處置策略需依其病理分類、分級、分子特徵與臨床表現綜合考量，主要治療方式包括手術切除、放射治療與化學治療。高惡性度腫瘤如膠質母細胞瘤，常採最大程度安全切除後接續放射線治療與口服替莫唑胺（temozolomide）化療；而對於低惡性度或位置特殊、手術風險較高的腫瘤，則可考慮影像監測、立體定位放射手術或藥物治療。近年也逐漸發展出標靶治療、免疫治療與對流增強型藥物輸送（convection-enhanced delivery）等新興策略，以克服血腦障壁限制，提升治療效果與延長病人存活期[15]。

多項流行病學研究指出，腦膜瘤、腦下垂體瘤與膠質母細胞瘤為成人最常見的原發性顱內腫瘤類型。Ostrom 等人於 2022 年發表的統計報告中明確指出，腦膜瘤為最常見的原發性腦瘤，其次依序為腦下垂體腫瘤與 GBM [16]。其中，腦膜瘤約佔全部原發性腫瘤的 39%，腦下垂體腫瘤佔約 16%，而膠質母細胞瘤則為最常見的惡性腦瘤，佔所有原發性腦瘤的約 14%。基於三者在臨床上的高發生率與代表性，本研究選擇腦膜瘤、腦下垂體瘤與膠質母細胞瘤作為影像自動診斷之目標腫瘤類型。

2.1.1 腦膜瘤

腦膜瘤（Meningioma）源自蛛網膜頂細胞，屬於典型的顱外腫瘤。腦膜瘤約佔所有原發性中樞神經系統腫瘤的 37~41%，亦構成近一半的良性顱內腫瘤[17]。CBTRUS 2024 全國性統計報告進一步顯示，在 2016~2020 年間，腦膜瘤為最常見的非惡性腦腫瘤，年齡調整後發生率為每十萬人口 10 例以上，遠高於其他顱內腫瘤[18]。依 WHO 2021 分類，腦膜瘤分為 Grade 1（良性）、Grade 2（非典型）與 Grade 3（惡性）；新版指南亦納入 TERT-promoter 突變與 CDKN2A/B 缺失等分子標記以協助預後評估[19]。

在 MRI 中，腦膜瘤的 T1 加權影像通常呈現與正常腦組織相近或略低的訊號強度；而 T2 加權影像則常見與周圍組織相近或略高的訊號。成像後腫瘤多呈現均勻且明顯的增強，常伴隨具診斷意義的硬腦膜尾徵象[20]。在 CT 掃描中，腫瘤常伴有鈣化現象，以及鄰近顱骨的骨質增厚（hyperostosis）。這些典型的影像特徵有助於腦膜瘤與其他顱內腫瘤的鑑別診斷[19]。

臨床表現與腫瘤部位密切相關。額葉病灶常導致人格改變或執行功能障礙；頂葉或中央區病灶可出現對側肢體無力或感覺缺失；顳葉病灶與癲癇及語言障礙相關；枕葉病灶則以視野缺損為主；位於蝶骨翼、視神經鞘或嗅溝的腫瘤分別可引起視力模糊、複視或嗅覺喪失；小腦或後顱窩腫瘤則易出現步態不穩及顱內壓增高所致頭痛、噁心與嘔吐等症狀[17]。

整體而言，腦膜瘤多為良性且生長緩慢，但其病灶位置與大小決定了症狀表型與治療時機；因此，結合分子分級或典型影像特徵進行早期診斷，對降低神經功能損害和改善預後至關重要。

2.1.2 腦下垂體瘤

腦下垂體瘤（Pituitary Adenoma）為一種源自腦下垂體前葉的良性腫瘤，其發生率約佔所有顱內腫瘤的 10~20%，為常見的腦部腫瘤之一[21]。腦下垂體位於顱底蝶鞍處，透過分泌多種激素如促腎上腺皮質素（ACTH）、甲狀腺刺激素（TSH）、生長激素（GH）、黃體與濾泡刺激素（LH/FSH）、泌乳素（PRL）等，參與人體的生長發育、代謝調節、生殖與水鹽平衡等重要生理功能，因此被譽為「內分泌系統的中樞」[22]。

腦下垂體瘤依其是否具有荷爾蒙分泌活性，可分為功能性與非功能性兩大類。功能性腫瘤會主動分泌過量激素，其中最常見者為泌乳素瘤（prolactinoma），可引發女性月經失調、乳溢症，男性則常見性慾低下與陽痿等症狀；其次為生長激素瘤，

會造成成人肢端肥大症與兒童巨人症；另外還有促腎上腺皮質激素瘤，會導致庫欣氏病表現[21, 23]。而非功能性腦下垂體瘤（non-functioning pituitary adenomas, NFPAs）則不會分泌具臨床意義的激素，通常會在影像學中偶然發現，或因腫瘤壓迫周邊結構造成症狀，如雙側顳側視野缺損、頭痛與下垂體功能低下[24, 25]。

臨床診斷腦下垂體瘤主要仰賴鼻腔 MRI 來評估腫瘤位置與範圍，並搭配內分泌功能檢查以判斷是否屬於功能性腫瘤；若腫瘤鄰近視交叉，建議加做視野檢查以早期偵測視神經壓迫徵象。根據 Endocrine Society 的臨床指引，對於腦下垂體偶發瘤（incidentaloma）患者，應進行完整激素檢測與定期影像追蹤，以確保病灶變化得以早期掌握[26]。

腦下垂體瘤的治療方式可以依腫瘤類型與症狀決定。泌乳素瘤患者以多巴胺促效劑（dopamine agonists）如 cabergoline 為一線治療藥物，其可有效抑制 PRL 分泌並縮小腫瘤體積[23]；對於因腫瘤壓迫視神經或荷爾蒙控制不佳者，則考慮行內視鏡經蝶竇手術，近期文獻指出此手術技術已日臻成熟，併發症風險低於 2%[27]。對於手術後腫瘤殘留或復發者，亦可採立體定位放射手術控制腫瘤生長，長期腫瘤控制率高達 85~95%，惟需注意晚期垂體功能衰退的風險[28]。

由於腦下垂體瘤常具進展緩慢、初期症狀不明顯之特性，臨床上常有延遲診斷情形。然而，已有研究指出若能及早發現並介入治療，不僅可顯著改善視神經功能，也能減少不可逆的內分泌失衡，因此提高對本病之警覺並落實篩檢與早期處置，對患者預後具有關鍵意義[25, 28]。

2.1.3 膠質母細胞瘤

膠質母細胞瘤（Glioblastoma, GBM）是成人最常見的原發性惡性腦瘤，約佔所有原發性腦與中樞神經系統腫瘤的 16%，年齡校正後的發生率約為每十萬人口 3.2 例[29]。GBM 病理上為高度異質性腫瘤，具快速增殖、廣泛浸潤與壞死等特徵。根據 WHO 2021 年的分類系統，GBM 被歸類為「IDH 野生型的第四級瀰漫性星狀細胞瘤」，其診斷可依據分子標誌特徵，包括端粒酶啟動子（TERT promoter）突變、EGFR 擴增，或第 7 號染色體增多與第 10 號染色體缺失（+7/−10）等複合異常，即便缺乏組織學的壞死與血管增生亦然[30]。

臨床上，GBM 的症狀多樣且進展迅速，常依腫瘤所在位置與其對周邊腦組織的壓迫與浸潤程度而異。常見非特異性症狀包括早晨起床時加劇的持續性頭痛、噁心與嘔吐，這些通常與顱內壓上升有關。若腫瘤侵犯功能性腦區，患者可能出現局部神經功能缺損，如肢體偏癱、語言障礙、視野缺損與步態不穩等。此外，約有 20~50% 的患者在初診時即以癲癇發作為表現，亦可出現記憶力衰退、專注力下降、性格與情緒變化等高階神經功能異常[31]。上述症狀往往缺乏特異性，易與其他神

經科疾病混淆，進而延誤診斷。

影像學診斷是 GBM 評估的重要步驟。首選工具為對比增強核磁共振(MRI)，其典型影像表現為具有中央壞死、邊界不規則的環狀增強病灶，並可見顯著的周邊水腫與腦實質侵犯[32]。進一步可輔以擴散加權成像(DWI)、灌流加權成像(PWI)及磁振波譜分析（MRS)，以利鑑別假性進展與腫瘤復發。這些先進的 MRI 技術能夠提供有關腫瘤細胞密度、血流動力學和代謝活動的資訊，對於提高診斷準確性和制定治療策略具有重要意義[33]。此外，電腦斷層掃描（CT）在急診或無法接受 MRI 者亦可作為初步檢查工具，特別是在偵測出血或鈣化病灶方面具價值[34]。

早期診斷 GBM 對病患的預後至關重要。雖然 GBM 目前仍無法根治，但若能於腫瘤尚處於較小體積、尚未廣泛侵犯重要功能區之前即進行手術切除與同步放化療，可明顯改善症狀控制與生活品質，並延長整體存活期[35]。研究亦指出，若於腫瘤進展階段才進行治療，許多患者可能已喪失手術切除的可行性，導致預後惡化[36]。因此，針對有進行性神經症狀或新發癲癇之中老年患者，應提高警覺並及早安排影像檢查以利確診與介入。

2.2 醫學影像在腦部腫瘤診斷之應用

MRI 是腦腫瘤診斷中不可或缺的工具，提供高解析度的軟組織對比，有助於精確判定腫瘤的大小、位置、邊界及對周邊腦組織的侵犯情形[37]。基本的 MRI 序列如 T1 加權影像（T1-weighted）、T2 加權影像（T2-weighted）、液體衰減反轉恢復序列（FLAIR）與擴散加權影像（Diffusion-weighted imaging, DWI）在臨床應用中最為常見。

T1 加權影像可清楚呈現腦部解剖構造，未增強的腫瘤通常呈現低訊號；而在注射含釓之對比劑後，腫瘤區域由於血腦屏障受損，會出現明顯增強訊號，有助於界定腫瘤邊界與壞死核心，為放射治療劃靶與手術導航提供依據[37]。T2 加權影像則強調水分含量，可顯示腫瘤內部的囊變或壞死區，而 FLAIR 序列則進一步抑制腦脊髓液訊號，增強腫瘤相關水腫與浸潤的對比度，有助於界定實質病變範圍[38]。DWI 透過偵測水分子擴散限制反映細胞密度變化，在鑑別腫瘤等級與早期偵測復發方面具有重要應用。惡性腫瘤如 GBM 常因細胞密度高而在 DWI 上呈高訊號，並伴隨 ADC（apparent diffusion coefficient）降低的現象[39]。

不同類型的腦腫瘤在 MRI 上通常具有各自典型的影像特徵。以腦膜瘤為例，T1 加權影像中腫瘤通常看起來與正常腦實質差不多或略暗，而在 T2 加權影像中則相對偏亮。經對比劑增強後，腫瘤會出現明顯且均勻的增強，常伴隨特徵性的「硬腦膜尾徵象（dural tail sign）」，這是區分腦膜瘤與其他顱內腫瘤的重要線索[20]。

腦下垂體腺瘤的影像表現則因腫瘤大小與組織性質不同而異。微腺瘤在 T1 影像中多偏暗，對比劑注射後訊號增強通常較晚出現，需搭配動態增強掃描以協助辨識；巨腺瘤則因體積較大，常見壓迫視交叉等周圍結構的情況，在 T2 影像中則多表現為略亮的訊號。DWI 影像有助於了解腫瘤的一致性與細胞密度，對預測手術風險亦具臨床價值[40, 41]。

GBM 是惡性程度極高的腦腫瘤，其影像表現具高度異質性。T1 影像中常見大片偏暗區域，對應壞死與非增強腫瘤組織；T2 與 FLAIR 影像則表現為廣泛高訊號，顯示周圍水腫或腫瘤浸潤。經對比劑增強後，常可見邊緣不規則的環狀增強，反映中央壞死與腫瘤血管新生；DWI 則可觀察到訊號變化受限的區域，顯示腫瘤細胞密度高、惡性程度強的特徵[42, 43]。

綜合上述，MRI 提供從解剖、結構、水腫到細胞密度等多層次資訊，能有效鑑別不同腦腫瘤類型，並協助治療規劃與預後評估，是現代神經腫瘤學中最核心的影像工具之一。

2.3 基於深度學習之腦部腫瘤診斷應用

隨著人工智慧技術的快速進展，深度學習（Deep Learning）已成為醫學影像分析領域中的關鍵工具。深度學習透過模擬人腦神經網路的層級架構，能自動從大量資料中學習高階語意特徵，無需依賴傳統手工設計特徵。這一特性使其特別適合應用於醫學影像中高度非結構化且具複雜模式的資料處理。對於腦部腫瘤診斷而言，深度學習可實現包括病灶檢測、腫瘤分割、類型分類、甚至預後預測等任務，有效輔助臨床判斷與決策[44]。目前已有大量研究證實，基於深度學習的模型在腦部腫瘤影像的分析中展現出高準確率與穩定性，特別是在 MRI 資料上的應用[45]。

2.3.1 卷積神經網路(Convolutional Neural Network)

卷積神經網路（Convolutional Neural Networks, CNNs）最早由 Fukushima 於 1980 年提出，其 Neocognitron 架構模仿生物視覺皮質，具備局部感受野與分層特徵提取的能力，奠定了後續深度學習網路的基礎[46]。然而，Neocognitron 並未配合有效的學習演算法。直至 LeCun 等人於 1989 年將反向傳播法（backpropagation）應用於卷積架構，並提出 LeNet 系列模型，CNN 才得以實際應用於手寫字辨識任務[47]。LeCun 等人後續發表的 LeNet-5 架構進一步整合卷積、池化與全連接層，證實了 CNN 可在最少前處理下學習高維影像的判別特徵，在手寫數字資料集 MNIST 上達到當時最佳的辨識效能[47]。

CNN 是深度學習中最早且最廣泛應用於影像分析的架構。CNN 特別擅長捕捉圖像中的區域性特徵，透過多層次的卷積（convolution）、激發（activation）、池化（pooling）與全連接層（fully connected layers）所組成的結構，能夠有效提取影像中由低階（邊緣、紋理）到高階（形狀、語意）的層級資訊。卷積層藉由局部接受域與參數共享機制學習區域特徵，激發函數導入非線性表現能力，池化層則進一步降低特徵圖維度並保留主要資訊，最後由扁平化後的全連接層進行分類。這種結構不僅能顯著減少模型參數，提升計算效率，也具備良好的圖像泛化能力，尤其適合處理腦部 MRI 等具有局部結構的醫學影像。

在腦部腫瘤的病灶分類任務中，CNN 因其優異的影像特徵提取能力，廣泛應用於 MRI 影像分析。研究者普遍採用 CNN 將 MRI 影像輸入網路中，以辨識不同類型的腦瘤，例如 GBM 、腦膜瘤與腦下垂體瘤等，進而輔助臨床進行準確的診斷與個別化治療規劃。

Swati 等人（2019）採用預訓練的 ResNet50 模型進行遷移學習，針對 MRI 影像進行特徵提取，並結合支援向量機（SVM）完成三類腦瘤（膠質瘤、腦膜瘤、垂體腺瘤）分類，在 Figshare MRI 資料集上達到 98.69% 的準確率、98.51% 的精

確率與 98.60% 的靈敏度，展現深度學習模型在特徵泛化與分類任務中的高效能表現[48]。

Sajjad 等人（2019）則開發一種多路徑 CNN 架構，整合 T1、T2 與 FLAIR 等多模態 MRI 影像，在 BraTS 資料集上進行腦瘤等級分類，達到 94.58% 的整體準確率，顯示多模態融合對提升辨識細節與腫瘤分級有明顯幫助[49]。

Vimala 等人（2023）提出一種基於遷移學習的混合式深度學習架構，應用於腦瘤影像的多類別分類任務。該研究使用 Figshare 公開 CE-MRI 資料集，涵蓋膠質瘤、腦膜瘤與垂體瘤三類腦瘤，並對 EfficientNet-B0 至 B4 模型進行微調與比較。實驗結果顯示，以 EfficientNet-B2 所建構的模型表現最佳，測試準確率達 99.06%，F1-score 為 98.79%。此外，研究亦結合 Grad-CAM 技術進行模型可視化，提升其於臨床應用中的解釋性與可信度[50]。

此外，雖然 ResNeSt-50d 模型尚未應用於腦部 MRI 疾病分類任務，但已有研究將其成功應用於其他醫學影像領域，顯示其具備高度潛力。透過融合分離式注意力機制（Split-Attention）與殘差學習架構，此模型在深層特徵提取與分類上展現良好表現。Raj 等人（2022）針對心肌炎（Myocarditis）患者的心臟 MRI 影像進行研究，採用 ResNeSt-50d 模型進行自動診斷，並與多種預訓練模型進行比較。實驗結果顯示，該模型在多項分類指標上皆取得優異成果，包括準確率（Accuracy）98.1%、精確率（Precision）98.3%、召回率（Recall）98.0%、以及 F1 分數（F1-score）98.1%，整體表現優於標準 CNN 架構，證實 ResNeSt-50d 可應用於醫學 MRI 影像中的高精度分類任務[51]。

Disci 等人（2025）採用六種預訓練卷積神經網路（CNN）模型結合遷移學習（transfer learning）對公開的腦部 MRI 影像資料集進行分類，將影像分為膠質瘤、腦膜瘤、腦下垂體瘤與無腫瘤四類。該研究利用 Xception、ResNet50、VGG16 與 DenseNet121 等架構，並搭配影像增強與特徵微調策略，以提升分類精度與模型泛化能力。其中 Xception 模型表現最佳，測試集加權準確率達 98.73%、加權 F1 分數為 95.29%，在處理類別不平衡上具良好穩定性。

2.3.2 Transformer

Transformer 架構最初由 Google Brain 團隊於 2017 年提出，透過論文〈Attention Is All You Need〉首次證明，僅使用注意力機制即可有效建構序列模型，並在機器翻譯任務上超越當時主流的循環神經網路（RNN）與卷積神經網路（CNN）架構[52]。該架構不僅提升了訓練效率，亦因其高度平行化的特性而大幅改善模型訓練時間與效果，使得 Transformer 成為自然語言處理（NLP）領域的主流基礎架構，衍生出如 BERT、GPT 等多種具代表性的變體。

隨著研究的推進，Transformer 架構也逐漸被引入電腦視覺領域。Dosovitskiy 等人提出 Vision Transformer（ViT），將影像切割為 patch 並視為序列處理，開啟了純 Transformer 在視覺任務中的應用可能[53]。此後，更多改良版本相繼被提出，如 Swin Transformer [54]與 Pyramid Vision Transformer（PVT）[55]，進一步提升其在影像分類、語意分割與物件偵測等任務中的表現。

相較於傳統 CNN 著重於區域性特徵提取，Transformer 架構具備全域建模能力，能有效捕捉影像中不同區域之間的長距依賴關係。其核心由多項模組化的部分構成。其中，自注意力機制（Self-Attention）讓每個影像區塊能與其他區塊建立關聯，進而建構整體語意結構。多頭注意力（Multi-Head Attention）則將注意力分成多個子空間，並行學習不同的特徵表示，提升模型的特徵表達能力。此外，位置編碼（Positional Encoding）透過引入相對與絕對位置信息，補足注意力機制中對空間結構的感知限制。在架構設計上，注意力模組後接前饋網路（Feed-Forward Network），並搭配殘差連接與 Layer Normalization，有助於穩定深層網路的訓練過程。原始 Transformer 採用編碼器–解碼器堆疊（Encoder–Decoder）架構，後續亦可依任務需求進行調整與簡化，成為推動各領域應用發展的基礎架構之一。

在醫學影像領域，Transformer 架構日益被應用於腦部腫瘤的分類任務，展現出顯著的潛力與優勢。Transformer 能將 MRI 影像劃分為 patch 並轉換為序列資料進行分析，藉由全域注意力機制強化對病灶位置、形態與邊界的辨識能力。這使得其在處理分布不規則、形狀多變的腦腫瘤特徵時，具有比 CNN 更強的全局理解與特徵融合能力。由於能同時整合多尺度與遠距資訊，Transformer 架構特別適合應用於腦部 MRI 影像中複雜病灶的分類任務，有助於提升模型在臨床決策支援系統中的準確性與泛化表現。

Meshram 等人（2023）針對腦部腫瘤診斷任務，提出一套基於 Swin Transformer 的深度學習架構，應用於 MRI 影像之自動化分類與偵測。研究團隊彙整自多個開放資料集共約 31,000 張 MRI 影像，並針對是否為腦瘤以及三種類型腫瘤（膠質瘤、腦膜瘤與腦下垂體瘤）進行分類訓練。透過資料增強與特徵提取技術輔助，該模型最終在分類任務中達到 99.51% 的準確率與 99.49% 的召回率，顯著優於傳統方法如 CNN、SVM 與 U-Net，在腦部 MRI 影像的特徵擷取與長距依賴建模方面具備高度優勢，有助於提升腫瘤分類的準確性與臨床實用性[56]。

Ahmed 等人（2024）提出一種結合 Vision Transformer（ViT）與 Gated Recurrent Unit（GRU）的混合模型，應用於腦腫瘤 MRI 影像分類，並結合可解釋人工智慧（XAI）技術提升模型透明度。實驗結果顯示，該模型在自建 BrTMHD-2023 資料集上達到 98.97% 的準確率與 97% 的召回率；在公開的 Kaggle 資料集上也取得 96.08% 的準確率，展現出優異的跨資料集泛化能力[57]。

在近期針對腦部腫瘤分類任務的研究中，EfficientFormer 被提出作為一種兼具速度與準確度的輕量級 Transformer 架構。Sajol 等人（2024）在多個 MRI 資料集上對多種深度學習模型進行比較分析，發現 EfficientFormer 雖然在分類準確率上並非表現最突出的模型，但其在推論速度方面具有顯著優勢。該模型透過「維度一致設計（dimension-consistent design）」與「延遲優化精簡策略（latency-driven slimming）」來降低計算負擔，展現出極高的處理效率，特別適合用於需要即時運算或資源受限的臨床應用場景。研究結果顯示，EfficientFormer 在保有良好分類表現的同時，大幅縮短單張影像的推論時間，為腦瘤自動化診斷模型的輕量化與部署提供了一項具潛力的解決方案[58]。

2.3.3 CNN 結合 Transformer

結合 CNN 與 Transformer 架構，主要是因為兩者在功能上具有互補性：CNN 擅長提取局部空間特徵，具備局部歸納偏差與高效的運算能力，特別適用於小樣本學習與邊緣設備上的應用；而 Transformer 則具備優異的全域建模能力，能有效捕捉圖像中不同區域間的長距離依賴，對於複雜語意理解與整體資訊整合具有顯著優勢。然而兩模型各自仍有彼此的缺陷，單一使用 CNN 難以建構全域語意脈絡，而純 Transformer 在資料量不足或計算資源有限時則容易出現泛化困難，因此融合兩者架構已成為提升模型效能與效率的重要策略。

近年已有多項研究嘗試結合 CNN 與 Transformer 的優點，以追求更穩定且具泛化能力的表現。以 CoAtNet 為例，該架構在網路深層交替結合卷積與自注意力模組，實驗結果顯示其在資料效率與泛化能力上皆優於單一架構[59]。Conformer 則進一步提出多尺度融合機制，動態整合局部與全域特徵，在分類與密集預測任務中展現出更高的準確率與泛用性[60]。針對邊緣裝置的需求，MobileViT 等輕量級模型則透過嵌入小型 Transformer 模組，在維持高速推論的同時仍能顯著提升準確率，展現混合架構在實務應用上的潛力[61]。

CNN 與 Transformer 的結合不僅能互補彼此在空間與語意建模上的不足，更因應了當代對於高精度、高效率與多場景適應性的實際需求，逐漸成為深度學習模型設計的發展趨勢。

Roy 等人（2025）在腦腫瘤 MRI 影像分類研究中，將 Pooling-based Vision Transformer（PiT）納入多種深度學習模型進行效能比較。實驗結果顯示 PiT 模型在四分類 MRI 資料集上達到 89.4% 的準確率，而在類別數較多且分布嚴重不均的 15 類與 44 類資料集中，準確率分別僅達到 73.9% 與 72.2%，F1 分數則為 73.6% 與 72.2%。根據研究結果指出，儘管 PiT 具備良好的分類效能，然而在面對高類別數與高度不平衡的醫學影像資料時，分類效能仍可能受到限制[62]。

2.4 基於深度學習之腦部腫瘤分割應用

目前應用於腦部腫瘤影像分析的深度學習分割方法，以語意分割（semantic segmentation）與實例分割（instance segmentation）為主流技術[63]。前者專注於像素層級的類別標註，後者則進一步區分相同類別中不同實例。儘管近年亦有研究嘗試引入如全景分割、層級分割、多階段分割與弱監督分割等進階方法，以應對複雜結構辨識與訓練資料不足的挑戰，本研究仍聚焦於語意分割與實例分割兩大方向，作為腦部腫瘤區域偵測與分析的主要策略。

2.4.1 語意分割

語意分割（semantic segmentation）是影像分析中一項重要任務，旨在將影像中每一個像素指派至特定的語義類別，從而達成對場景中物體的精確區域識別。不同於圖像分類僅針對整張影像進行標註，或物件偵測著重於目標位置與邊界框，語意分割提供像素級別的語義理解，有助於實現更細緻的影像內容解析。Yu 等人（2018）指出，語意分割廣泛應用於自駕車、遙測、醫療影像等領域，其挑戰包括處理複雜場景中的多尺度物體、精細邊界區分與類別不平衡等問題，因此促使研究者提出多種演算法架構以提升分割效能與語義一致性[64]。

語意分割（semantic segmentation）為當前腦部腫瘤 MRI 影像分析中最常見的深度學習方法之一，透過對每一像素或體素進行語意標註，可精確區分腫瘤的不同區域如壞死、實質腫瘤與水腫範圍等，有助於臨床診斷與治療規劃[65]。其中 U-Net 架構因其對稱編碼器-解碼器設計與跳躍連接，在醫學語意分割領域取得廣泛應用，成為 BraTS 系列競賽的基礎模型之一[66]。近年來，許多研究者再進一步結合 3D 卷積、Transformer 模型及多模態 MRI（如 T1、T2、FLAIR）融合策略，以強化模型對腫瘤異質性與邊界的辨識能力[11]。Ahamed 等人（2023）考量醫療資料隱私與跨機構模型泛化能力，也將聯邦學習（federated learning）應用於語意分割模型訓練，展現出更高的實務潛力[67]。整體而言，語意分割方法已從傳統 CNN 架構，演進至結合多模態、多中心與自注意力機制的進階模型，成為腦腫瘤影像分析中的核心技術之一。

Liao 等人（2023）提出改良式 Swin-UNet 模型，融合 Swin Transformer 的全域建模能力與 UNet 的編解碼架構，進行腦腫瘤 MRI 影像分割。研究透過引入空間與通道注意力的 Efficient Paired Attention（EPA）模組，有效提升特徵提取與分割準確度。在 BraTS2021 資料集的測試中，Swin-UNet-EPA 模型的 IoU 達 0.84、Dice coefficient 為 0.915，優於原始的 UNet （IoU 0.81, Dice 0.889）與 Swin-UNet（IoU 0.83, Dice 0.910）。實驗過程 loss 降低明顯，也顯示該模型訓練穩定，對腫瘤邊界的分割更為精確，展現其於腦腫瘤分割任務的優越效能[68]。

2.4.2 實例分割

實例分割（Instance Segmentation）是一項結合物體偵測與語意分割的任務，不僅需正確偵測影像中的所有物體，並以邊界框標示位置，還需為每個物體個體預測出像素級的遮罩。He 等人（2017）指出，實例分割的核心在於區分同一類別中不同個體，因此同時具備物體偵測的區域級辨識能力與語意分割的像素級分類需求，任務更為複雜。此外，研究強調空間對齊的精確性對實例分割至關重要，任何位移誤差都可能導致遮罩品質下降，因此需設計能保留精細空間資訊的網路架構，以確保分割結果的準確性[69]。

近年來，Mask R-CNN 與 YOLO 等實例分割模型被廣泛應用於腦部腫瘤的影像分割任務，展現出良好的分割精度與模型彈性。其中，Mask R-CNN 具備同時進行物體偵測與像素級遮罩預測的能力，能有效辨識並分離不同的腫瘤實體，對於腫瘤邊界的準確定位與後續臨床處置具有實用價值。為提升模型於腦部 MRI 影像中的分割表現，許多研究進一步結合注意力機制與多尺度特徵融合設計，增強模型對細節與複雜背景的辨識能力。而基於 YOLO 架構所發展的實例分割方法則憑藉其高速推論與輕量化架構，在維持即時處理能力的同時，也透過整合語意分割頭與邊界優化策略，在醫學影像中達成不錯的分割效果。這些模型的持續發展與改良，使實例分割在腦部腫瘤影像分析中成為兼具精度與效率的重要研究方向。

Jeong 等人（2020）延伸至三維卷積架構，發展出 3D Mask R-CNN 以處理 DSC perfusion MRI 影像，其分割結果達 Dice score 0.90，突顯三維資訊在腫瘤體積辨識上的重要性 Mask_R-CNN。

Ragab 等人（2024）提出一項利用 YOLOv8 進行腦腫瘤實例分割的研究，針對醫學影像診斷中分割精度與自動化程度不足的問題提出解決方案。該研究以 BraTS 等公開 MRI 資料集為基礎，並將 YOLOv8 架構改為同時具備檢測與分割功能。實驗結果顯示，模型於腫瘤區域的 mask 分割達到 mAP50-95 值為 0.95，precision 為 0.99、recall 為 0.90，並於各項 F1、IoU 等指標上表現優異，顯示 YOLOv8 能有效辨識腫瘤邊界且具有高度穩健性。此結果驗證 YOLOv8 在醫學影像中應用於腦腫瘤分割的可行性與潛力[70]。

Yuan 等人（2024）結合通道與空間注意力模組，並優化 RoIAlign 操作，在 BraTS 公開資料集上達成 mIoU 94.56%、Precision 90.72%、Recall 91.68% 的表現，顯示注意力設計對於提升遮罩品質具有顯著效果[71]。

Mask R-CNN 架構若結合多尺度特徵金字塔、注意力機制以及三維卷積等技術，可進一步提升其於腦部腫瘤實例分割任務中的準確性與泛化能力，並成為深度學習於醫學影像分割應用中的重要研究方向。此外，近年來以 YOLO 為基礎所延

伸的實例分割模型也展現出高度潛力，其優勢在於運算效率高、推論速度快，特別適用於實時或資源受限的臨床應用場景。透過整合語意分割頭（segmentation head）與精細邊界回歸技術，YOLO 系列亦能兼顧偵測與分割效能，成為實例分割任務中具競爭力的替代方案。

第 3 章　研究方法

本研究針對腦部 MRI 影像進行腫瘤區域之分割與疾病類別之分類，整體研究流程如圖 3.1 所示，主要包含資料蒐集與處理、模型訓練、以及模型評估三大階段。首先，從實際臨床取得之 MRI 影像資料中，涵蓋正常（Normal）、膠質母細胞瘤（Glioblastoma）、腦膜瘤（Meningioma）、腦下垂體腫瘤（Pituitary adenoma）等四種類型。資料經前處理步驟後，進行標註以產生語意遮罩，供後續分割模型訓練使用。接著，針對訓練資料進行增量處理，，以提升模型對不同影像條件的適應能力。資料完成標註與增強後，進行訓練集、驗證集與測試集之劃分，並將訓練資料輸入至多種分割模型與分類模型中進行訓練。最終，使用測試集對訓練完成之模型進行驗證與評估，全面評量模型之分割與分類效能。

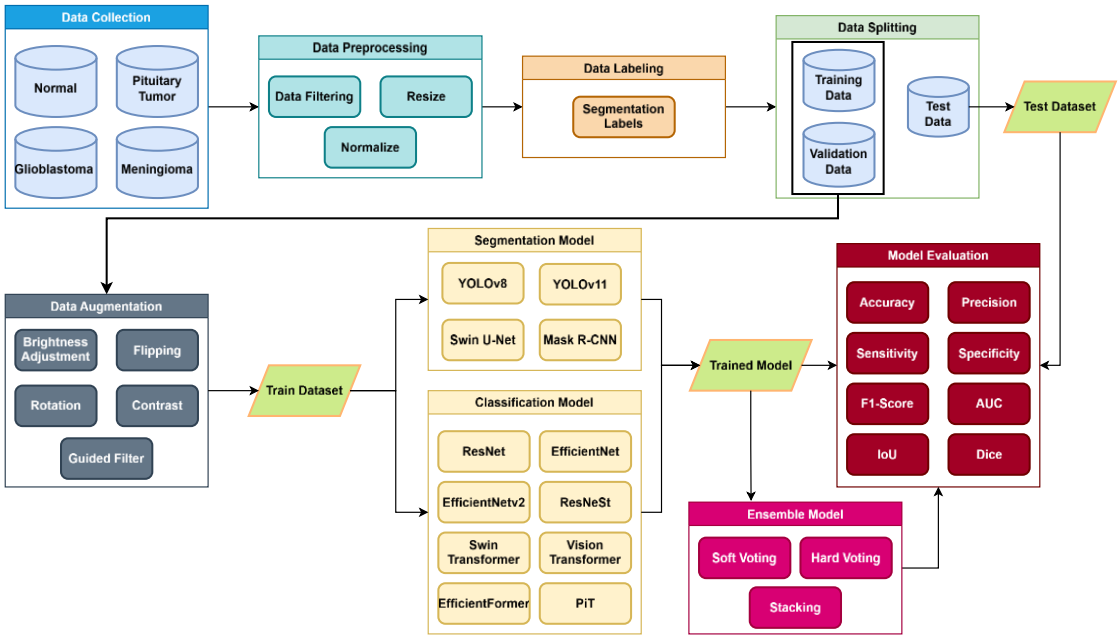


圖 3.1 研究流程圖

3.1 資料集介紹

本研究所使用之資料來自臺中榮民總醫院提供之影像資料集，整體資料是由三種不同疾病的資料集所組成，第一份為為膠質母細胞瘤患者之 MRI 影像（IRB No: CE25332C），其中包含 32 位病患，數量為 3616 張的 MRI 影像；第二份為腦膜瘤患者之 MRI 影像（IRB No: CE25332C），其中包含 33 位病患，數量為 4356 張的 MRI 影像；第三份為腦下垂體瘤患者之 MRI 影像（IRB No: CE25332C），其中包含 31 位病患，數量為 4402 張的 MRI 影像。

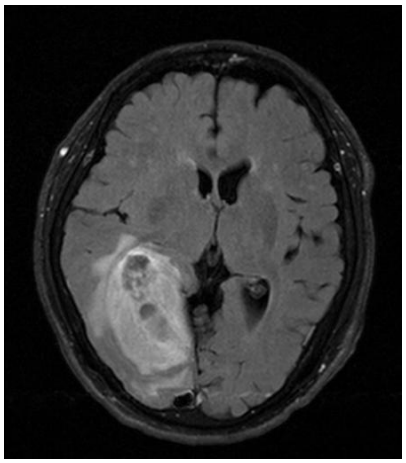


圖 2.2 膠質母細胞瘤 MRI 影像



圖 3.3 腦膜瘤病患 MRI 影像

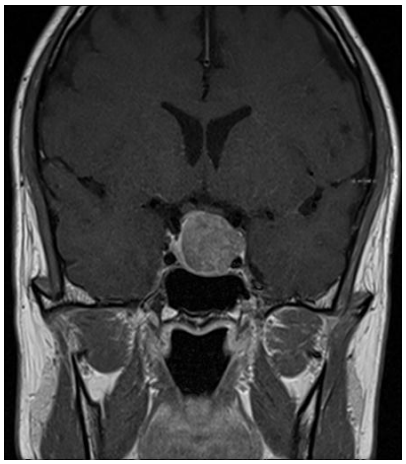


圖 3.4 腦下垂體瘤病患 MRI 影像

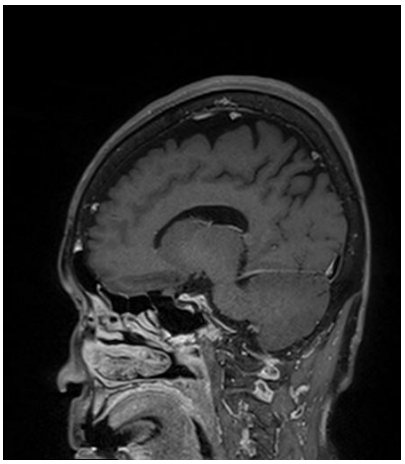


圖 3.5 無腫瘤 MRI 影像

本研究所採用之腦部 MRI 影像資料涵蓋多角度（Axial、Sagittal、Coronal）與多序列（T1、T2、FLAIR）的掃描結果。多角度影像能呈現腫瘤於不同解剖切面下的空間分布情形，而多序列影像則提供組織在不同成像參數下的訊號變化，有助於提升模型對腫瘤邊界與類型的辨識能力。此類異質性資料可強化模型學習不同視角與對比下的腫瘤特徵，進而提升整體預測表現。

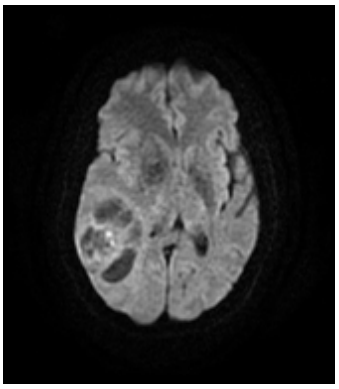


圖 3.6 Axial 橫斷面影像示意圖

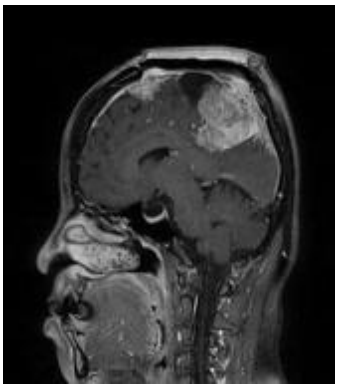


圖 3.7 Sagittal 矢狀面影像示意圖

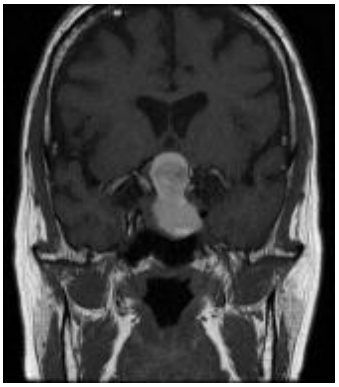


圖 3.8 Coronal 冠狀面影像示意圖

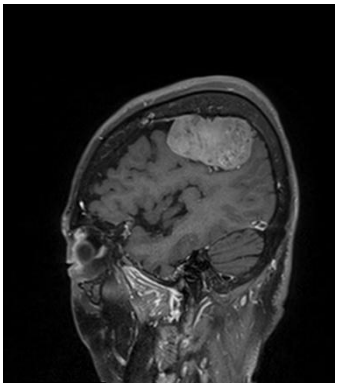


圖 3.9 T1 影像示意圖

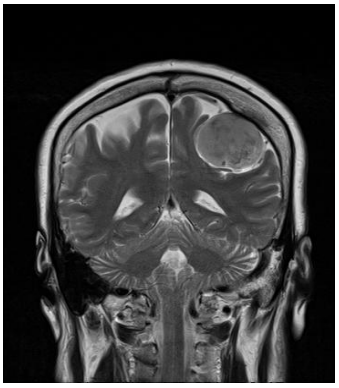


圖 3.10 T2 影像示意圖

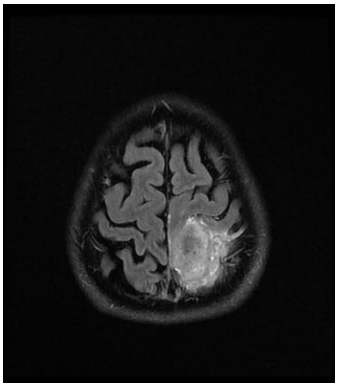


圖 3.11 Flair 影像示意圖

3.2 資料預處理

本研究原始資料共收集 12374 張腦部 MRI 影像，為提升分析的準確性與模型訓練的有效性，需先進行資料篩選。影像篩選的過程是由台中榮民總醫院神經外科臨床醫師協助指導，透過醫師教導與提供參考放射影像判讀準則，剔除整體資料中無法清楚辨識腦部結構或無助於腫瘤診斷之切片，最終保留具判讀價值的 660 張 MRI 影像。這些影像涵蓋三類別疾病影像，分別為膠質母細胞瘤（Glioblastoma）、腦膜瘤（Meningioma）、腦下垂體瘤（Pituitary adenoma）。經過與醫師討論後，本研究選擇於整體資料集中挑選出沒有受腫瘤病理特徵影響的影像作為無腫瘤（Normal）影像。總資料數量詳如表 3.1、3.2 與 3.3 所示。

表 3.1 資料篩選前後數量表

影像類別	篩選前數量	篩選後數量
Glioblastoma	3616 張	231 張
Meningioma	4356 張	234 張
Pituitary adenoma	4402 張	195 張
Normal		393 張

表 3.2 影像序列分布表

影像類別	T1	T2	Flair
Glioblastoma	125 張	90 張	16 張
Meningioma	137 張	73 張	24 張
Pituitary adenoma	128 張	55 張	12 張
Normal	204 張	130 張	59 張

表 3.3 影像軸向分布表

影像類別	Axial	Sagittal	Coronal
Glioblastoma	155 張	16 張	60 張
Meningioma	129 張	45 張	60 張
Pituitary adenoma	21 張	65 張	109 張
Normal	232 張	76 張	85 張

為提升模型效能與泛化能力，在影像輸入模型前，進一步對影像先進行了標準化（normalization）與尺寸調整（resize）處理。標準化將影像像素值轉換至 0 至 1 的範圍，以統一數值尺度並降低梯度計算的波動，進而提升模型訓練的穩定性與收斂速度；而 resize 則將所有影像統一調整為一致尺寸，以符合深度學習模型對輸入大小的要求，確保特徵萃取與分類的一致性與穩定性。

經過以上的預處理步驟後，本研究將整體腦瘤影像資料集進行資料切分，以利後續模型訓練與效能評估。首先，將整體資料集依 8:2 的比例分為訓練集與測試集，接著為了在訓練過程中進行模型參數調整與早停機制的驗證，再將上述訓練集依 8:2 的比例切分為最終的訓練集與驗證集。經此處理後，資料集分配比例分別為：訓練集佔 64%、驗證集佔 16%、測試集佔 20%。再以訓練集進行後續的增量方法。

3.3 資料標註

本研究使用 LabelMe 作為腦部 MRI 影像的標註工具。LabelMe 為麻省理工學院開發之開源圖形化標註軟體，廣泛應用於影像分割與物件辨識任務。該工具支援以多邊形（polygon）形式對影像中目標區域進行標註，使用者可透過直覺化操作介面，自由勾勒腫瘤輪廓，建立高品質的像素級標註資料。

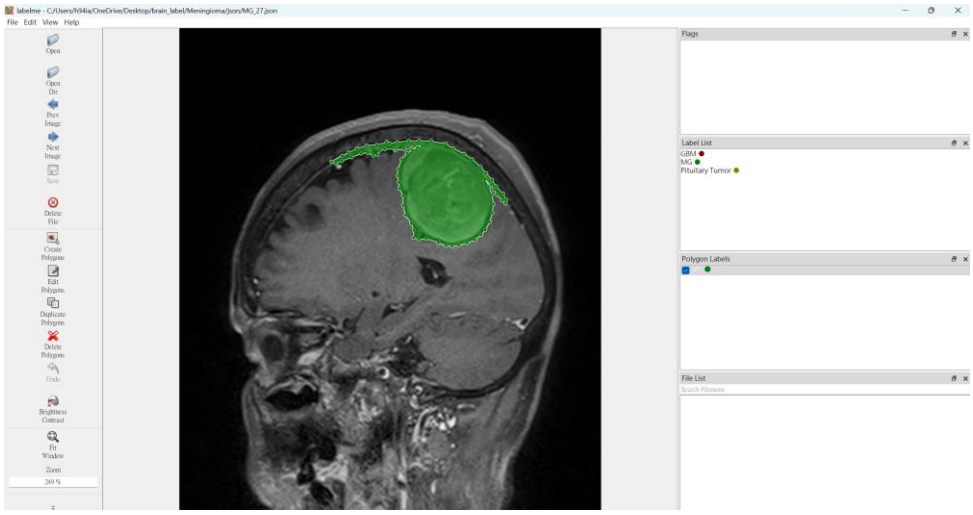


圖 3.12 LabelMe 標註操作示意圖

影像經過標註後，LabelMe 會自動產出對應的 JSON 格式標註檔案，內容包含原始影像檔名、每個標註對象的類別名稱（label）、多邊形邊界的座標點（x, y）、影像大小等資訊。透過這些資料，可進一步轉換為模型訓練所需的格式，如語意遮罩（semantic mask）、實例遮罩（instance mask），或 YOLO segmentation 所需的座標格式，使模型能夠學習各類腫瘤的空間分布與形狀特徵，提升分類與分割的準確性。

根據不同分割模型的輸入需求，常見的標註格式主要包括語意遮罩（semantic mask）、實例遮罩（instance mask），以及 YOLO segmentation 格式。語意遮罩是將影像中每一像素依照所屬類別進行標記，適用於像是 U-Net 或 Swin-Unet 等語意分割模型；實例遮罩則進一步區分同一類別中不同個體的標註，常見於 Mask R-CNN 等實例分割模型，其中 Mask R-CNN 需使用 COCO 格式進行訓練，該格式以 JSON 結構儲存每張影像的類別資訊、多邊形遮罩與邊界框等標註資料。至於 YOLO segmentation 則以多邊形座標表示目標區域邊界，並轉換為特定的文字檔格式，供 YOLOv8 或 YOLOv11 segmentation 模型使用。不同格式對應不同的訓練需求與模型架構，因此須根據實際應用進行轉換。

本研究將標註完成後的 JSON 資料進一步轉換為適合模型輸入的遮罩格式。由於本研究之 MRI 影像皆僅包含單一腫瘤區域，因此語意遮罩已足以提供模型所需的空間資訊，因此針對語意分割模型與實例分割模型，皆以語意遮罩圖（semantic mask）為基礎進行轉換。儘管語意遮罩本質上未區分個體，但在本研究的資料皆屬於單一腫瘤的情境下，亦可轉為單實例遮罩並整理為 COCO 格式輸入 Mask R-CNN 模型。另一方面，為訓練 YOLOv8 與 YOLOv11 segmentation 模型，則將多邊形邊界資訊轉換為 YOLO 所需的 .txt 格式，內含腫瘤類別編號與相對於影像尺寸之多邊形座標。透過此一轉換流程，確保標註資料符合各模型架構之輸入要求，並提升訓練階段的效率與穩定性。

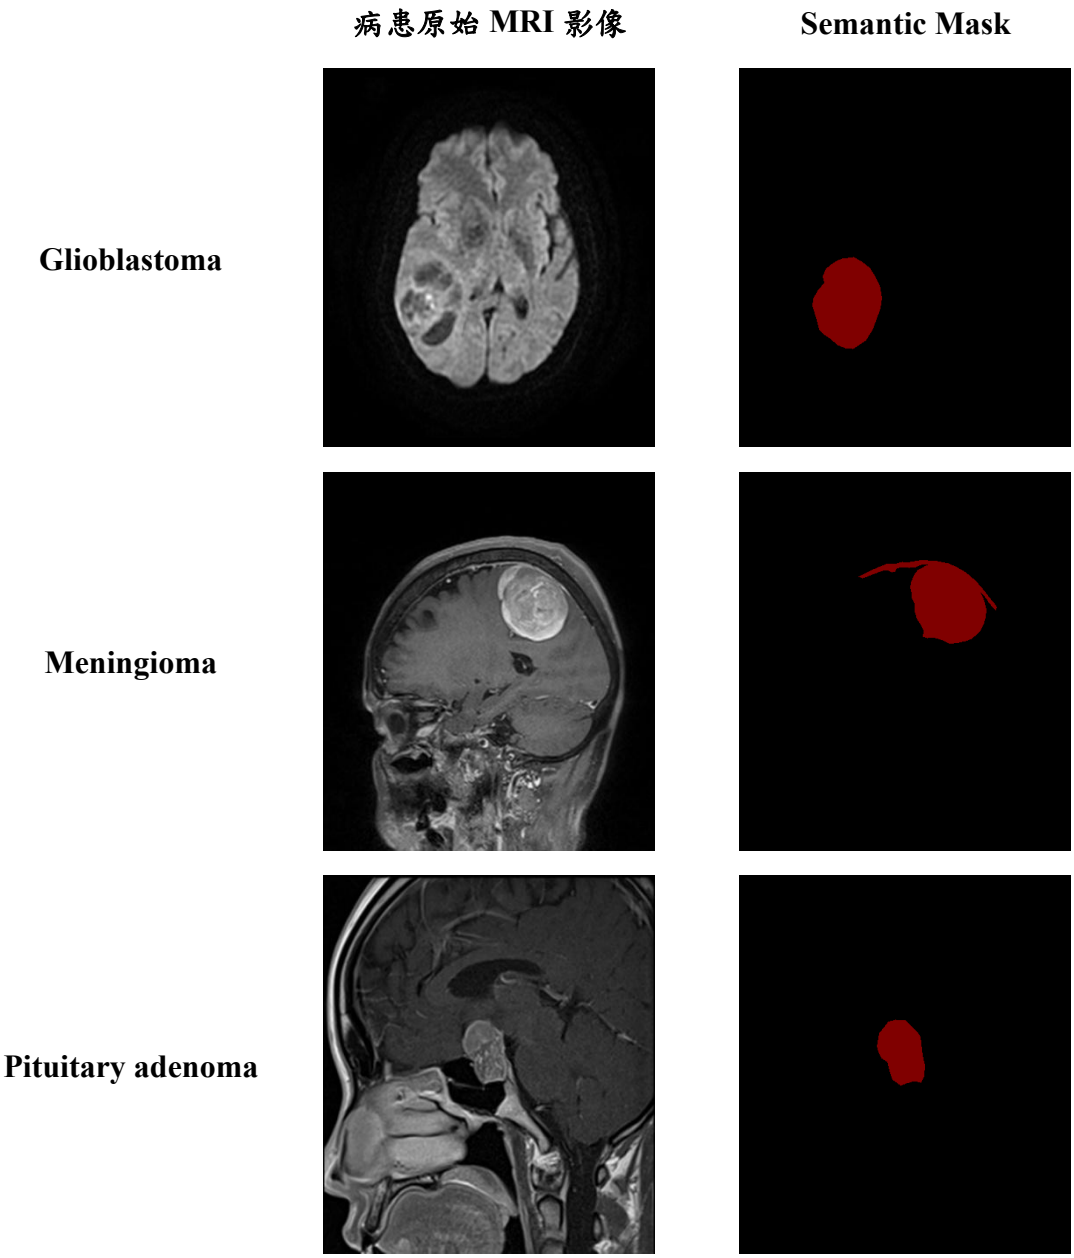


圖 3.13 各類別腫瘤原始 MRI 與 Semantic Mask 示意圖

3.4 資料增量

在深度學習的影像分析任務中，資料增量（data augmentation）是一項常見且關鍵的資料預處理技術，透過對原始資料進行多樣化的轉換操作，以模擬不同的輸入條件，進而提升模型的泛化能力與預測表現。常見的增量方式包括旋轉（rotation）、翻轉（flipping）、縮放（scaling）、亮度調整（brightness adjustment）、雜訊添加（noise injection）等。這些技術能有效緩解過擬合問題，並提升模型在有限資料下的訓練效能，特別是在醫學影像領域如 MRI 或 CT，資料取得受限的情況下，增量策略更顯重要。

然而，若未考量資料本身的結構特性與診斷語意，可能導致不合適的增量操作破壞原始影像的幾何資訊與語意一致性，進而影響模型的學習效果與最終表現。在與腦腫瘤相關的研究當中，有學者指出，當資料增量操作造成腫瘤區域位置異常、方向錯置，或改變腫瘤與鄰近腦組織的空間關係時，可能會破壞原始影像中具診斷意義的結構與語意特徵，使模型學習到錯誤或不具臨床意義的模式，進而影響分類與分割的準確性。舉例來說，過度旋轉或鏡像翻轉的操作，可能導致模型將病灶誤判為正常區域，或對腫瘤邊界產生混淆，降低模型的泛化能力與臨床應用的穩定性[72]。因此在醫學影像分析中實施資料增量時，應特別重視腫瘤區域的結構穩定性與語意一致性，避免使用會改變解剖配置或產生語意混淆的操作，並透過實驗驗證各種增量策略對模型表現的實質影響，以確保其效益大於潛在風險。

基於上述對於資料結構與診斷語意一致性的考量，本研究在設計資料增量策略時採取較為保守的做法，避免使用可能大幅改變腫瘤空間位置或影像語意的轉換方式。為在不影響影像解剖結構的前提下，提升模型訓練時的多樣性與穩健性，最終選擇了六種較為溫和且具語意保留性的增量方法，分別為：亮度提高、亮度降低、對比拉伸、水平翻轉、小角度旋轉與導引濾波（guided filter）。

本研究選擇之增量方法是為了能在維持腫瘤區域邊界與解剖關係的同時，模擬不同掃描條件或視覺變化情境，增強模型對於光照變化與邊緣特徵的辨識能力。其中，小角度旋轉可提供適度的構圖多樣性，而不致於扭曲腫瘤在腦部影像中的相對位置；guided filter 則是一種基於局部線性模型的影像平滑技術，其特點在於透過導引影像引導濾波過程，以保留原始影像中的邊緣結構，同時進行去雜訊處理。本研究中所採用的導引影像為標註所取得之腫瘤遮罩，透過該遮罩作為引導可使濾波操作更聚焦於腫瘤區域，提升邊界資訊的保留程度。此特性對於醫學影像中需要精準邊界判斷的任務尤為重要，特別是在語意分割應用中，有助於提升模型對腫瘤邊緣的辨識能力與分割表現。

為更具體說明本研究所採用之資料增量方式，圖 3.14 至圖 3.20 依序示範了原始 MRI 影像以及經亮度提高、亮度降低、對比拉伸、水平翻轉、小角度旋轉與 guided filter 等六種方法處理後的影像。這些方法乃經多次測試與驗證後選定，能有效提升影像多樣性並增強模型對光照、對比度及構圖變化的適應能力，同時避免因過度變形而影響腫瘤區域的空間結構，在不破壞影像語意與結構的前提下，資料增量操作所引入的視覺多樣性。訓練集的資料在經過上述的方法增量後，Glioblastoma 的影像從 148 張增量至 1036 張，Meningioma 的影像從 150 張增量至 1050 張，Pituitary adenoma 的影像從 125 張增量至 875 張，Normal 的影像從 252 張增量至 1764 張。

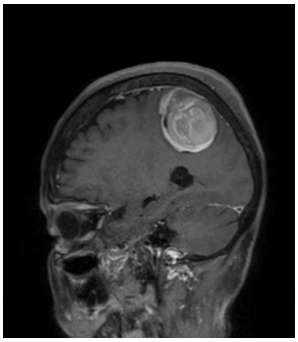


圖 3.14 原始影像

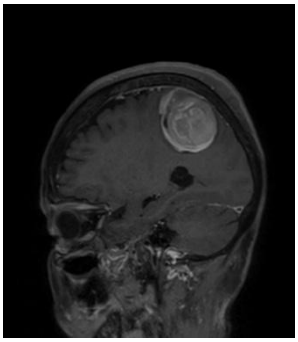


圖 3.15 亮度降低後影像

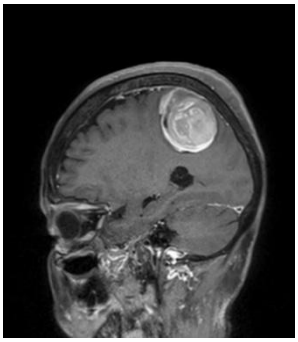


圖 3.16 亮度提高後影像

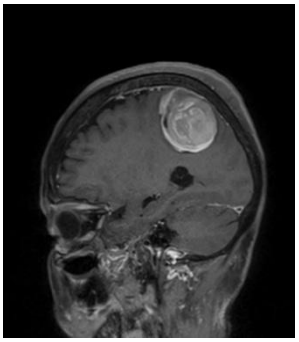


圖 3.17 對比拉伸後影像

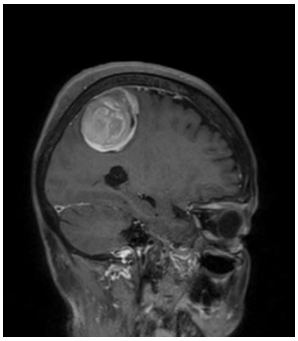


圖 3.18 水平翻轉後影像

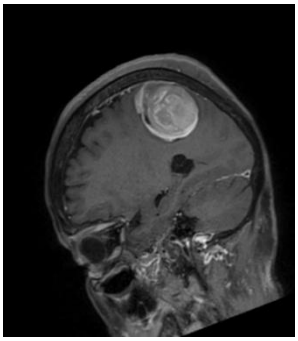


圖 3.19 小角度旋轉後影像

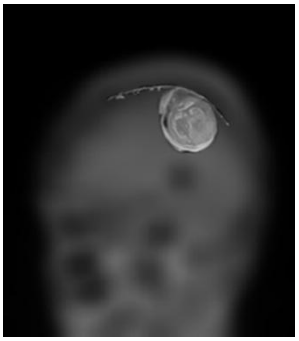


圖 3.20 導引濾波後影像

3.5 影像分類模型架構

在影像分類任務中，深度學習模型透過多層結構自動提取輸入影像的關鍵特徵，進而進行分類判斷。隨著模型架構的持續演進，研究者提出了多種具代表性的分類模型，其在特徵表徵能力、計算效率與應用泛化上展現出不同的優勢。在傳統研究中，以卷積神經網路（CNN）為基礎的模型最為常見，透過局部接受域與參數共享機制，有效捕捉影像中的局部紋理與結構特徵。近年來，隨著資料規模與硬體運算能力的提升，Transformer 架構因具備全域注意力機制，亦被廣泛引入至視覺任務中，用以捕捉影像中長距離依賴與整體語意。除此之外，亦有多種融合 CNN 與 Transformer 優勢的混合式架構陸續被提出，進一步提升模型於複雜視覺場景下的辨識能力與泛化表現。

在醫學影像分析領域，分類模型的選擇尤為關鍵。由於醫學影像常具有高解析度、低對比度與細緻結構等特性，分類模型需具備優異的特徵擷取與語意理解能力，才能準確辨識細微病灶或異常區域。在此背景下，模型的結構設計不僅攸關準確率與穩定性，更直接影響臨床應用層面的可行性與可靠性。

本研究基於上述考量，選擇了八種具代表性的影像分類模型，評估其於腦部 MRI 影像分類任務中的應用表現。這些模型依其設計架構與運作機制，可分為三種類型，其中包含傳統 CNN 架構、純 Transformer 架構，與融合 CNN 與 Transformer 優勢的混合式架構。各類模型在特徵提取方式、語意建模策略與結構設計上各具優勢，以下將依類型分別進行介紹與說明。

3.5.1 純 CNN 架構

(1) ResNet50

ResNet50 為 He 等人於 2016 年提出之深度卷積神經網路架構[73]，屬於 ResNet（Residual Network）系列的代表模型。該架構的核心貢獻在於引入「殘差學習」（residual learning）機制，透過跳躍連接（skip connection）將輸入訊號直接加至卷積模組的輸出，有效緩解深層網路中常見的梯度消失與性能退化問題，使網路深度得以大幅提升而不致性能下降。其基本運作可由公式 1 表示：

$$y = F(x, \{W_i\}) + x \tag{1}$$

其中 x 為輸入特徵，$F(x, \{Wi\})$ 為經由多層卷積運算後的變換函數，y 為殘差模組的輸出。ResNet50 採用 Bottleneck 設計，即每個殘差區塊由三層卷積（1×1、3×3、1×1）所組成，總共堆疊 50 層。該架構於 ImageNet 上表現優異，Top-1 準確率可達約 76%，並廣泛應用於分類、偵測、分割等任務。其穩定的訓練特性與深層語意建模能力，使其適合應用於腦部 MRI 影像分類等需要細緻判別的任務。

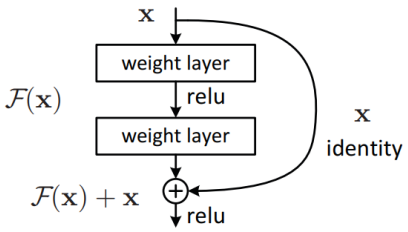


圖 3.21 ResNet 殘差單元（Residual Block）示意圖。輸入 x 經由兩層含參數的卷積與 ReLU 非線性轉換後形成 $F(x)$，並與原始輸入 x 相加形成輸出 y [73]。

(2) EfficientNet-B0

EfficientNet-B0 為 Tan 與 Le 於 2019 年提出之高效率深度卷積神經網路架構[74]，屬於 EfficientNet 系列的基礎模型。該架構的核心貢獻在於引入「複合縮放」（Compound Scaling）策略，透過一組比例係數（α, β, γ）在固定每秒浮點運算次數（Floating-point operations per second , FLOPS）增幅下，同步擴展網路的深度（depth）、寬度（width）與輸入解析度（resolution），克服傳統僅針對單一維度放大所導致的資源浪費與效能飽和問題。其縮放規則可由公式 2 表示：

$$depth: d = \alpha^{\phi} \ , width: w = \beta^{\phi} \ , resolution: r = \gamma^{\phi}$$
$$s.t.\ \alpha \cdot \beta^2 \cdot \gamma^2 \approx 2 \quad \alpha \geq 1, \beta \geq 1, \gamma \geq 1 \tag{2}$$

其中 ϕ 為使用者指定的縮放指數，控制資源投入，$\alpha, \beta, \gamma \geq 1$ 為透過網格搜尋所設定之比例係數，用於平衡三者間的資源分配。

EfficientNet-B0 架構是由神經結構搜尋（Neural Architecture Search）生成，主體由多層 MBConv（Mobile Inverted Bottleneck Convolution）單元組成，並於各單元中整合 Squeeze-and-Excitation（SE）注意力機制以加強通道特徵重加權。模型整體共包含九個主要階段，自初始的 3×3 卷積層開始，依序經過多個不同核大小與展開倍率（expansion ratio）的 MBConv 模組，最後經 1×1 卷積與全局平均池化後進行分類。整體設計呈現空間維度逐步縮小、通道數遞增之特性，形成高效能的層級特徵提取流程。

EfficientNet-B0 在 ImageNet 上可達成 77.1% 的 Top-1 準確率，僅使用約 5.3 百萬個參數與 0.39 G FLOPS 的計算量，展現出極高的參數效率與分類能力。與傳統深層網路如 ResNet 相比，EfficientNet-B0 在大幅減少模型規模與運算成本的前提下，仍能維持相當水準的辨識效能。在腦部 MRI 分類任務中，模型需兼顧結構輕量化與特徵辨識力，EfficientNet-B0 透過深度可分離卷積與通道重加權的 Squeeze-and-Excitation 模組，有效提升對重要特徵的敏感度，同時保留計算效能與訓練穩定性，因此適合作為本研究的分類架構基礎。

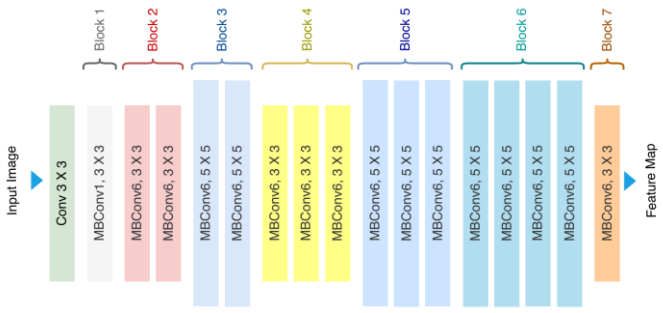


圖 3.22 EfficientNet-B0 架構示意圖[75]

(3) ResNeSt50d

ResNeSt 為 Zhang 等人於 2020 年提出之深度卷積神經網路架構[76]，為 ResNet 之改良版本，其名稱意指「Split-Attention Network based on ResNet」。該架構的主要貢獻在於於殘差模組中導入「分割注意力機制」（Split-Attention Mechanism），結合多路徑特徵表徵與通道間的注意力加權，進一步提升模型對於不同視覺特徵的辨識能力。

其核心模組為 Split-Attention Block，其設計可視為將輸入特徵圖依據 cardinality（群組數）與 radix（子分割數）分群，對各子分割特徵進行轉換與融合，並基於全域上下文資訊計算每個通道的注意力權重，最終再透過殘差加總機制完成特徵整合。其通道融合機制可由公式 3 表示：

$$V_k^c = \sum_{i=1}^{R} a_k^i(c) \cdot U_{R(k-1)+i} \tag{3}$$

其中 V_k^c 為第 k 群第 c 個通道的加權輸出，U_j 為每個分割特徵，$a_k^i(c)$ 為根據全域平均池化後的上下文向量計算之 softmax 權重。

ResNeSt 採用與 ResNet 類似之 Bottleneck 設計，透過堆疊改良過的殘差模組構成完整網路，常見版本如 ResNeSt-50、ResNeSt-101 等。該架構在 ImageNet 上可達成超過 81% 的 Top-1 準確率，優於同級別的 ResNet 與 SENet 架構，並在物體偵測與語意分割等下游任務中展現卓越性能。其優異的速度與準確率平衡，使其特別適用於腦部 MRI 影像等需要高精度辨識之醫學影像分類與分割任務。

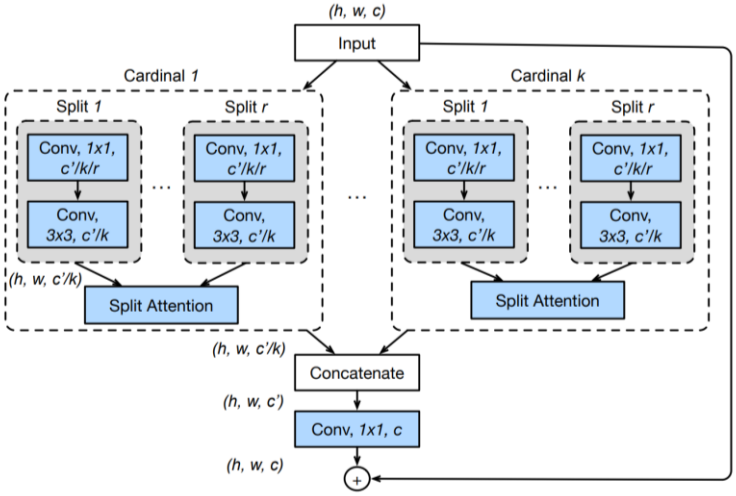


圖 3.23 ResNeSt 單元架構示意圖[76]

(4) EfficientNetV2

EfficientNetV2 為 Tan 與 Le 等人於 2021 年提出之卷積式深度神經網路架構[63]，屬於 EfficientNet 系列的第二代版本。該架構延續 EfficientNetV1 中以複合式縮放（Compound Scaling）策略達成精度與效率平衡之設計理念，並針對實際訓練時間、模型參數與推論效能進行全方位優化。與前一代相比，EfficientNetV2 引入更具彈性的結構搜尋方法與改良型模組設計，使得模型在保持高準確率的同時，訓練時間可大幅縮短，且在小模型設定下仍具備優異效能，特別適用於如腦部 MRI 等對效能與運算資源均有要求之應用場景。

EfficientNetV2 架構主要由兩種模組構成：傳統的 MBConv（Mobile Inverted Bottleneck Convolution）與新增的 Fused-MBConv 模組。其中，MBConv 採用 1×1 卷積進行特徵擴張，並搭配 3×3 深度可分離卷積（depthwise convolution）與 Squeeze-and-Excitation（SE）機制以提升表徵能力；而 Fused-MBConv 則將特徵擴張與卷積運算合併為一個標準 3×3 卷積操作，省略深度可分離卷積流程，藉此提升記憶體存取效率與早期訓練穩定性。兩者模組操作流程可簡要表示如公式 4：

$$\begin{aligned} &MBConv(x) \\ &= x + Conv_{1\times1}^{proj}(SE(Swish(BN(DWConv_{3\times3}(Swish(BN(Conv_{1\times1}^{exp}(\cdot)))))))) \\ &FusedMBConv(x) = Conv_{1\times1}^{proj}(Swish(BN(Conv_{3\times3}(x)))) \end{aligned} \tag{4}$$

除了架構上的調整，EfficientNetV2 亦導入逐步式學習（progressive learning）訓練策略，以進一步縮短總訓練時間。此策略在訓練初期使用較低解析度輸入與輕量化資料增強方式，並隨訓練進程逐漸提升影像尺寸與資料擴增強度，藉此加速模型收斂並避免早期過擬合。

實驗結果顯示，EfficientNetV2 在 ImageNet 分類任務上，相較於 V1 與其他主流卷積架構（如 ResNet、RegNet），可在相同或更短訓練時間內達成更高之 Top-1 準確率。在參數數量與 FLOPs 相近情況下，EfficientNetV2 擁有更佳的訓練穩定性與推論效率。其結構設計兼顧模型表現與訓練效率，特別適合應用於醫學影像分類任務中對高解析輸入與快速收斂有所需求之情境。

3.5.2 純 Transformer 架構

(1) Vision Transformer

Vision Transformer（ViT）為 Dosovitskiy 等人於 2021 年所提出之純 Transformer 架構的影像分類模型[53]，突破傳統卷積神經網路於視覺任務上的主導地位。該模型受自然語言處理中 Transformer 架構成功的啟發，捨棄卷積操作，改以將輸入影像劃分為固定大小之 patch，並將每個 patch 經線性嵌入後組成序列，再輸入標準的 Transformer Encoder。此設計能使模型具備全域的注意力建模能力，有效捕捉影像中長距依賴關係。

ViT 模型輸入為尺寸為 $H \times W \times C$ 的影像 x，首先被分割為 $N = \frac{HW}{P^2}$ 個大小為 $P \times P$ 的 patch，並展平成向量後經線性映射到維度 D 的嵌入空間，形成 patch embedding。其整體流程可由公式 5 進行描述：

$$
\begin{aligned}
z^0 &= [x_{class}; x_p^1; x_p^2; \dots; x_p^N E] + E_{pos} \\
z'_\ell &= MSA\big(LN(z_{\ell-1})\big) + z_{\ell-1}, \qquad \ell = 1, \dots, L \\
z_\ell &= MSA\big(LN(z_\ell)\big) + z_\ell, \qquad \ell = 1, \dots, L \\
y &= LN({z^0}_L)
\end{aligned}
\tag{5}
$$

其中，x_{class} 為額外加入的分類 token，其於最後一層的輸出 ${z^0}_L$ 作為整張影像的表示，輸入至最終的 MLP 預測分類結果。ViT 架構不具備 CNN 固有之平移不變性與局部接受域，因此在資料量不足時較難訓練；然若進行大規模資料集（如 ImageNet-21k 或 JFT-300M）預訓練後，再微調於目標任務，則可達到甚至超越 ResNet 等傳統 CNN 架構的表現。ViT 在 ImageNet 上最高可達 Top-1 準確率 88.55%，展現出優異的分類能力與跨任務泛化性。

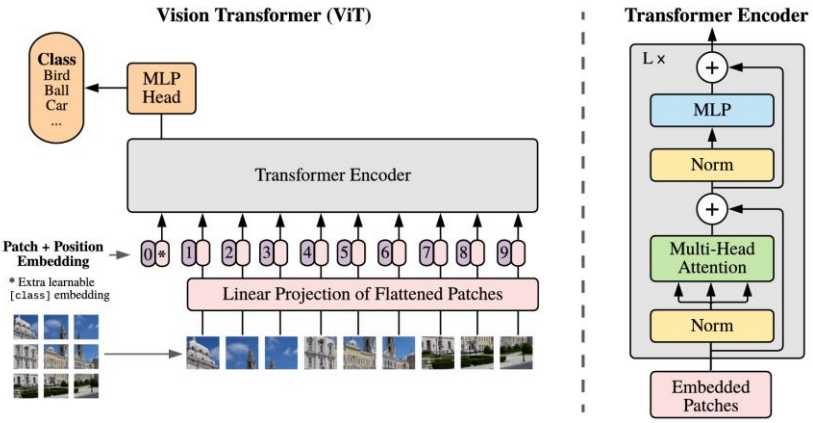


圖 3.24 Vision Transformer 模型架構示意圖[53]

(2) Swin Transformer V2

Swin Transformer V2 為 Liu 等人於 2022 年提出之改良型視覺 Transformer 架構[77]，為 Swin Transformer 系列之延伸與強化版本。原始 Swin Transformer 架構融合層級化設計與移動視窗注意力機制（shifted window attention），有效結合全域建模能力與局部性特徵，廣泛應用於影像分類、物件偵測與語意分割等視覺任務。Swin Transformer V2 則針對大規模模型訓練中常見之不穩定性、預訓練與下游任務間解析度落差，以及大量標註資料需求等挑戰，提出三項核心技術改良，成功實現參數規模達 30 億、支援 1536×1536 高解析輸入之視覺模型。

首先，Swin Transformer V2 採用殘差後正規化（residual post-normalization）策略，將原本位於殘差模組開頭之 LayerNorm 移至模組尾端，有效抑制深層網路中激發值幅度累積現象，提升大模型訓練穩定性。其次，提出縮放餘弦注意力（scaled cosine attention），將原先之點積注意力替換為標準化餘弦相似度運算，以降低注意力權重極端值之發生機率。其注意力運算公式如公式 6：

$$\mathrm{Sim}(q_i, k_j) = \frac{\cos(q_i, k_j)}{\tau} + B_{ij} \tag{6}$$

其中 $\cos(q_i, k_j)$ 為查詢向量與鍵向量間之餘弦相似度，τ 為可學習之縮放參數，B_{ij} 則為相對位置偏差項。

第三項技術為對數間距連續位置偏差（log-spaced continuous position bias, Log-CPB）。該方法透過一組由少量參數構成的前饋神經網路（meta-network），以相對座標作為輸入，自動學習並生成對應之相對位置偏差值，使模型能夠適應任意視窗尺寸下的位置關係，進而顯著提升模型於不同解析度間之轉移能力。相對座標之對數轉換公式如公式 7：

$$\begin{aligned} \widehat{\Delta x} &= sign(\Delta x) \cdot log(1+|\Delta x|) \\ \widehat{\Delta y} &= sign(\Delta y) \cdot log(1+|\Delta y|) \end{aligned} \tag{7}$$

為進一步降低記憶體資源需求，Swin Transformer V2 引入 ZeRO 優化器、activation checkpointing 以及序列式注意力運算等策略，使得在使用常規 GPU（如 A100-40G）條件下亦能訓練參數量達 30 億之模型。此研究亦採用自監督預訓練技術 SimMIM，以減少對大規模標註資料之依賴。在僅使用約 7000 萬張圖像進行預訓練情況下，SwinV2-G 模型即於多項視覺任務中達成最佳表現，顯示其優異之跨任務適應性與可擴展性。

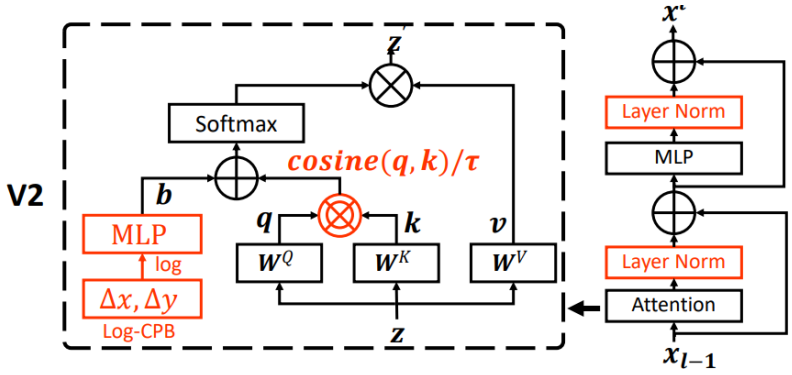


圖 3.25 Swin Transformer V2 模型架構示意圖[77]

(3) EfficientFormer

EfficientFormer 為 Li 等人於 2022 年提出之輕量化 Vision Transformer 架構[78]，其核心目標為於有限運算資源下達成高準確率與低延遲之影像分類性能，特別適用於行動裝置與邊緣端場景。相較於傳統 Vision Transformer 仰賴多頭自注意力（Multi-Head Self-Attention, MHSA），EfficientFormer 捨棄此高計算成本設計，改以基於通道與空間注意力之 MetaBlock 實現全域建模能力，並結合卷積特性以提升局部感知能力與推論效率。

整體架構採五階段層級設計（stage-wise design），前三階段為 MobileNetV2 構型所組成之 inverted bottleneck block，進行低成本之局部特徵提取；第四與第五階段則為 EfficientFormer 所提出之 MetaBlock。該模組由兩個並行分支組成，分別對應通道注意力（Channel Attention）與空間注意力（Spatial Attention），透過融合兩者輸出建構具備語意整合能力的全域特徵表示。

通道注意力分支中，首先對輸入特徵 $X \in R^{B\times C\times H\times W}$ 進行全域平均池化（Global Average Pooling），接續使用兩層線性變換與非線性函數組合生成注意力權重，具體運算如公式 8 所示：

$$X_{ca} = X \cdot \sigma(W_2(\delta(W_1(GAP(X))))) \tag{8}$$

其中，GAP 表示 Global Average Pooling，W_1 與 W_2 為學習到的線性轉換權重，δ 為 ReLU 函數，σ 為 sigmoid 函數。該設計可動態調整各通道之重要性，強化語意辨識能力。

空間注意力分支則使用 depthwise convolution 進行空間位置關係建模，其計算公式如公式 9：

$$X_{sa} = X_{ca} \cdot \sigma(DWConv(X_{ca})) \tag{9}$$

最終兩分支融合後之輸出經 channel shuffle 操作重組通道資訊，並透過殘差連接與輸入特徵相加形成 MetaBlock 輸出如公式 10：

$$Y = X + Shuffle(X_{sa}) \tag{10}$$

其中 Shuffle 表示通道間重新排列操作，用以促進資訊流動與跨通道互動。整體 MetaBlock 架構有效模擬 Transformer 中之全域建模特性，卻大幅降低計算複雜度，推論速度與記憶體使用顯著優於傳統 MHSA 架構。

EfficientFormer 移除了 LayerNorm 與位置編碼等設計，簡化模型結構，提升硬體友善性。以 EfficientFormer-L1 為例，僅使用約 5.3M 參數與 0.51B FLOPs，即可於 ImageNet 上達成 Top-1 準確率 79.2%。整體而言，EfficientFormer 於模型準確度與效率間取得優異平衡，為醫學影像分類等需兼顧精度與推論速度之應用場景提供具實用性之解決方案。

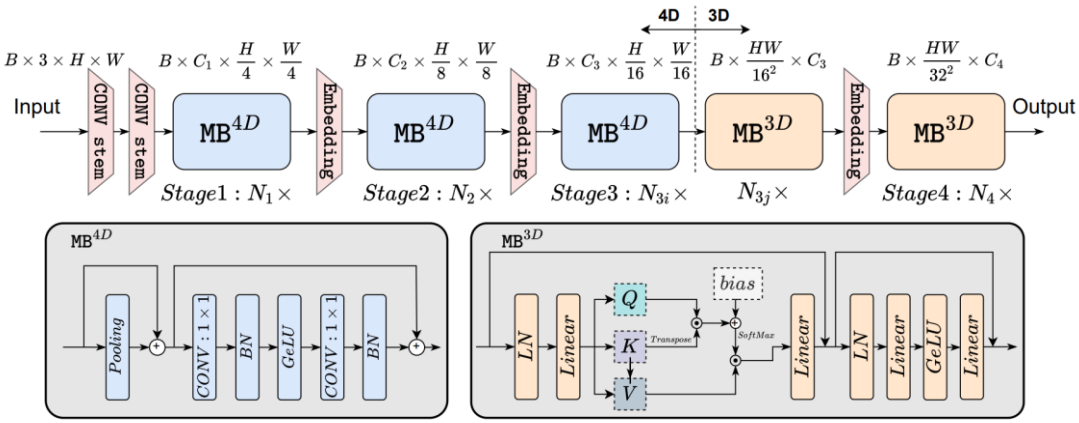


圖 3.26 EfficientFormer 模型架構示意圖[78]

3.5.3 CNN 與 Transformer 混合型架構

(1) Pooling-based Vision Transformer

Pooling-based Vision Transformer（PiT）為 Heo 等人於 2021 年提出之視覺轉換器架構，屬於 ViT（Vision Transformer）系列架構之延伸改良版本[79]。該模型的核心設計理念在於引入 CNN 中常見之「空間降維」策略，透過新設計之 Pooling 機制，使模型能在不同深度階段逐步降低特徵圖之空間解析度，同時擴增通道數，藉此提升模型之表現能力與泛化能力。此設計可望解決原始 ViT 架構中各層維持固定空間尺寸所導致之表徵效率不足問題。

為實現空間縮減功能，PiT 採用一種專為 Transformer 設計之 Pooling Layer。該層首先將輸入 token 重塑（reshape）為具有空間結構的三維特徵圖，接著透過 depth-wise convolution 進行空間降採樣與通道擴增，最後再轉換回二維 token 形式以供後續 Transformer Block 使用。對於非空間性之 Class Token 則以全連接層（Fully-connected layer）調整其維度，使其能與其他 token 同步進行處理。

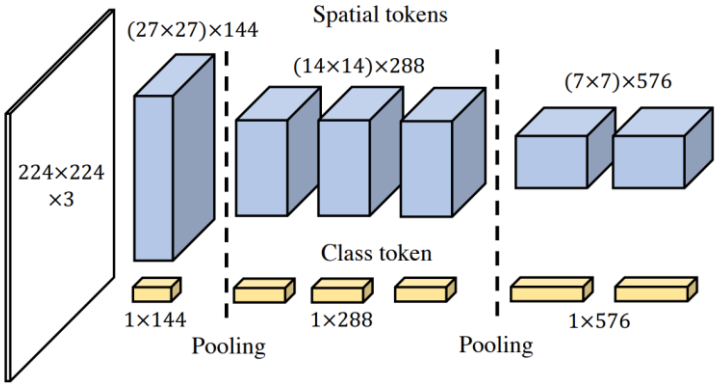


圖 3.27 PiT 模型架構示意圖[79]

3.6 集成學習方法

為了提升分類模型的穩定性與整體預測效能，本研究採用集成學習（Ensemble Learning）策略，包含投票法（Voting）與疊加法（Stacking）兩種方法。前者透過整合多模型的輸出結果進行預測決策，後者則利用多模型的預測結果作為次級模型（meta-model）的輸入，進行更進一步的決策學習。

3.6.1 投票法（Voting）

投票法為一種常見的集成學習策略，旨在結合多個模型的預測結果，以提升整體預測的穩定性與準確性。其核心概念在於透過多模型對同一輸入資料進行獨立預測，並根據預測結果進行整合決策。由於不同模型在不同樣本上可能具備互補的分類能力，投票法能有效平衡單一模型可能出現的偏差或誤判，進而提升整體系統的分類效能。

投票法可依整合方式的不同，區分為硬投票與軟投票兩種形式，分別對模型輸出的類別或機率進行整合。此方法不需額外訓練新模型，實作上相對簡便，且具備良好的解釋性與彈性，廣泛應用於多分類問題中。在本研究中，投票法作為模型融合的手段之一，用以整合多個分類模型的預測輸出，進一步提升腦部腫瘤影像分類任務中的表現穩定性。

(1) 硬投票

硬投票（Hard Voting）是一種基於多數決原則的模型融合方法，其運作方式為針對每一筆輸入資料，蒐集所有基礎模型（base models）所預測的最終類別標籤，並選擇其中出現次數最多的類別作為最終預測結果。此方法不考慮各模型預測的置信度或機率分佈，而僅以類別出現的頻率進行決策，具有實作簡單、計算效率高等優點[80]。

當所有模型對同一輸入資料做出相同預測時，硬投票的決策與單一模型一致；而在模型意見分歧時，透過多數原則可避免單一模型誤判導致的偏差，使整體預測結果更具穩定性。若出現票數相同的情況，則可採用預設的優先順序或隨機方式進行決策。由於硬投票僅依據類別標籤進行統計整合，特別適用於模型輸出為離散類別、且各模型整體表現相近的情境。

(2) 軟投票

軟投票（Soft Voting）為一種考慮模型預測機率分佈的融合方法，其運作方式為針對每一筆輸入資料，蒐集各基礎模型對所有類別的預測機率，並將這些機率值進行加總或加權平均，最終選擇機率總和最高的類別作為預測結果。與硬投票僅依據類別標籤不同，軟投票能夠反映模型對各類別的信心程度，因此能在預測不確定性較高的情境中提供更細緻的決策依據[81]。

此方法在各模型表現差異明顯時特別具備優勢，因為可透過加權分配反映對特定模型的信任程度。例如，對於性能較佳的模型可給予較高權重，以強化其在最終決策中的影響力。軟投票適用於分類模型輸出為機率向量的情境，並可靈活整合多模型的資訊，有助於提升整體預測準確率與穩定性。

3.6.2 疊加法（Stacking）

疊加法（Stacking）是一種進階的集成學習方法，透過訓練一個次級模型來整合多個基礎模型的預測結果，以進一步提升整體分類性能。其核心概念在於：基礎模型各自學習輸入資料的不同特徵表現，而次級模型則學習如何根據這些預測輸出做出更準確的最終判斷[82]。

在本研究中，Stacking 採用五折交叉驗證（5-Fold Cross-Validation）策略建構次級模型。具體而言，首先將訓練資料劃分為五個子集，針對每一折，使用其中四折資料訓練所有基礎模型，並對剩餘一折資料進行預測，重複此程序直至所有資料皆產生預測結果。將此過程所蒐集的預測輸出作為新的特徵，對應原始標籤後形成次級訓練資料，並據此訓練一個次級分類模型。

在測試階段，所有基礎模型以完整訓練集訓練後，對測試資料進行預測，並將預測結果輸入至已訓練完成的次級模型，以產出最終預測結果。此方法能夠有效捕捉不同模型間的互補性，並提升分類系統的泛化能力與穩定性，特別適用於多模型結合的影像分類任務中。

3.7 影像分割模型架構

影像分割（Image Segmentation）為計算機視覺領域中的核心任務之一，其目的在於將影像中的像素依據所屬目標或語意意義進行分群，以達到區域分割與物件辨識的目的。在醫學影像分析中，影像分割扮演著關鍵角色，特別是在腫瘤、病灶、器官等解剖結構的定位與定量評估上，皆仰賴準確的分割結果做為臨床診斷與治療規劃之依據[64]。

隨著深度學習技術的迅速發展，傳統依賴手工特徵與經驗式規則的分割方法逐漸被資料驅動的端對端學習架構所取代。早期由 Long 等人提出的全卷積網路為首個將卷積神經網路應用於影像語意分割的模型[83]，將分類網路中的全連接層改為卷積層，實現不同解析度特徵的空間對應輸出。後續的 U-Net 架構則針對醫學影像的特性進行改良，透過對稱性的編碼器與解碼器結構，並搭配跳接（skip connection）保留空間細節，成為醫學影像分割領域的主流方法[84]。

依據任務目標與標註方式，影像分割可分為三大類型：語意分割（Semantic Segmentation）、實例分割（Instance Segmentation）與全景分割（Panoptic Segmentation）[85]。語意分割著重於區分不同類別的像素，忽略個別實體的差異；實例分割則需同時區分不同類別與個體實體；全景分割則綜合上述兩者，為每一個像素指派特定實體與類別標籤。深度學習方法在這三大分割任務上皆展現出高度的可塑性與優異表現。

此外，近年來也有多項研究將 Transformer 架構引入影像分割任務，發展出結合 CNN 與 Transformer 優勢的混合式模型。例如 TransUNet 採用 U-Net 架構為基礎，並以 Vision Transformer（ViT）作為編碼器以強化全域語意建模能力[86]；Swin-Unet 則進一步將 Swin Transformer 應用於 U 型架構之中，透過滑動視窗機制（shifted windows）保留區域結構資訊，同時提升模型對長距依賴的建模能力[87]。這類架構有效結合局部與全域特徵處理能力，顯著改善醫學影像中邊界模糊、結構複雜等分割挑戰，逐漸成為當前深度學習分割技術的重要發展方向。

為有效執行腦部 MRI 影像中腫瘤區域之準確分割，本研究選擇四種具代表性的深度學習分割模型，分別為 YOLOv8、YOLOv11、Swin-Unet 與 Mask R-CNN。上述模型涵蓋語意分割與實例分割兩大主流類型，分別對應不同標註格式與臨床應用需求。其中，YOLOv8 與 YOLOv11 為近年發展之即時分割架構，結合物件偵測與遮罩預測能力，具備快速推論與高效運算之優勢；Swin-Unet 則屬於基於 Transformer 架構的語意分割方法，適合處理形狀變異與邊界模糊的腫瘤區域；而 Mask R-CNN 則屬於實例分割方法，能有效分離個別腫瘤實體，對於多病灶或非對稱分布的腫瘤影像具有優勢。

3.7.1 YOLO

YOLO（You Only Look Once）為一種單階段（one-stage）的物件偵測架構，由 Redmon 等人於 2016 年首次提出[88]，其核心思想為「將物件偵測視為一個回歸問題」，即透過單一神經網路，直接從影像中預測每個網格區塊內可能存在的物件位置與類別。相較於傳統兩階段方法需要先提取候選區域再分類，YOLO 架構具備高效、即時的推論能力，尤其適用於資源受限或需快速處理的場景。

在 YOLO 架構中，輸入影像首先經由多層卷積神經網路提取特徵，並被劃分為 $S \times S$ 個網格，每個網格負責預測固定數量的邊界框（bounding boxes）及其對應的分類機率與置信度。隨著 YOLO 系列版本的演進，其在偵測精度、運算效率與架構靈活性上皆有顯著提升，尤其是自 YOLOv5 以後由 Ultralytics 發展的版本，開始支援可擴展模組化設計與多任務學習輸出。

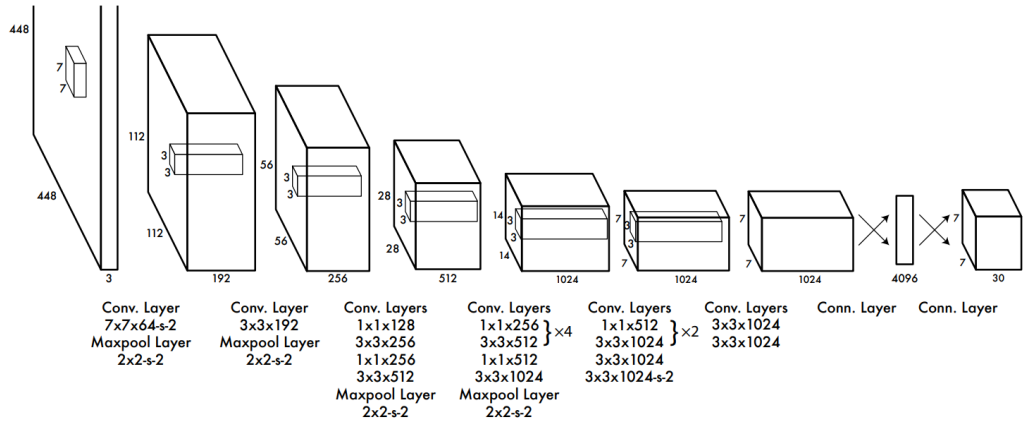


圖 3.28 YOLO 原始架構示意圖

特別值得注意的是，傳統 YOLO 架構僅支援物件偵測任務，然而從 YOLOv7-seg 與 YOLOv8 開始，YOLO 系列逐漸拓展至影像分割任務。這些版本在原有偵測頭（detection head）之外，新增分割支路（segmentation branch），可輸出對應之像素級遮罩（mask），實現類似於語意分割與實例分割的任務需求。此舉使得 YOLO 架構得以兼顧高效率與像素精度，並廣泛應用於自駕車、智慧工業、與醫學影像分析等領域。

YOLO 系列的演進不僅包括網路架構的革新，也包含訓練策略與預測邏輯的優化。以下將分別介紹本研究所採用之 YOLOv8 與 YOLOv11，說明其設計改良、分割能力與在腦部腫瘤影像分析中的適用性。

(1) YOLOv8

YOLOv8 為 Ultralytics 於 2023 年初推出之新一代 YOLO 架構，為 YOLO 系列首個正式整合分割任務支援的版本。與先前版本不同，YOLOv8 採用全新的 anchor-free 設計，捨棄傳統錨框（anchor box）機制，改以中心點預測與邊界回歸方式進行定位，有效簡化訓練流程並提升模型泛化能力。其骨幹網路採用輕量化設計，包含 C2f（Concatenate-Conv-Conv-Fuse）模組，強化特徵重用性與上下文融合能力[89]。

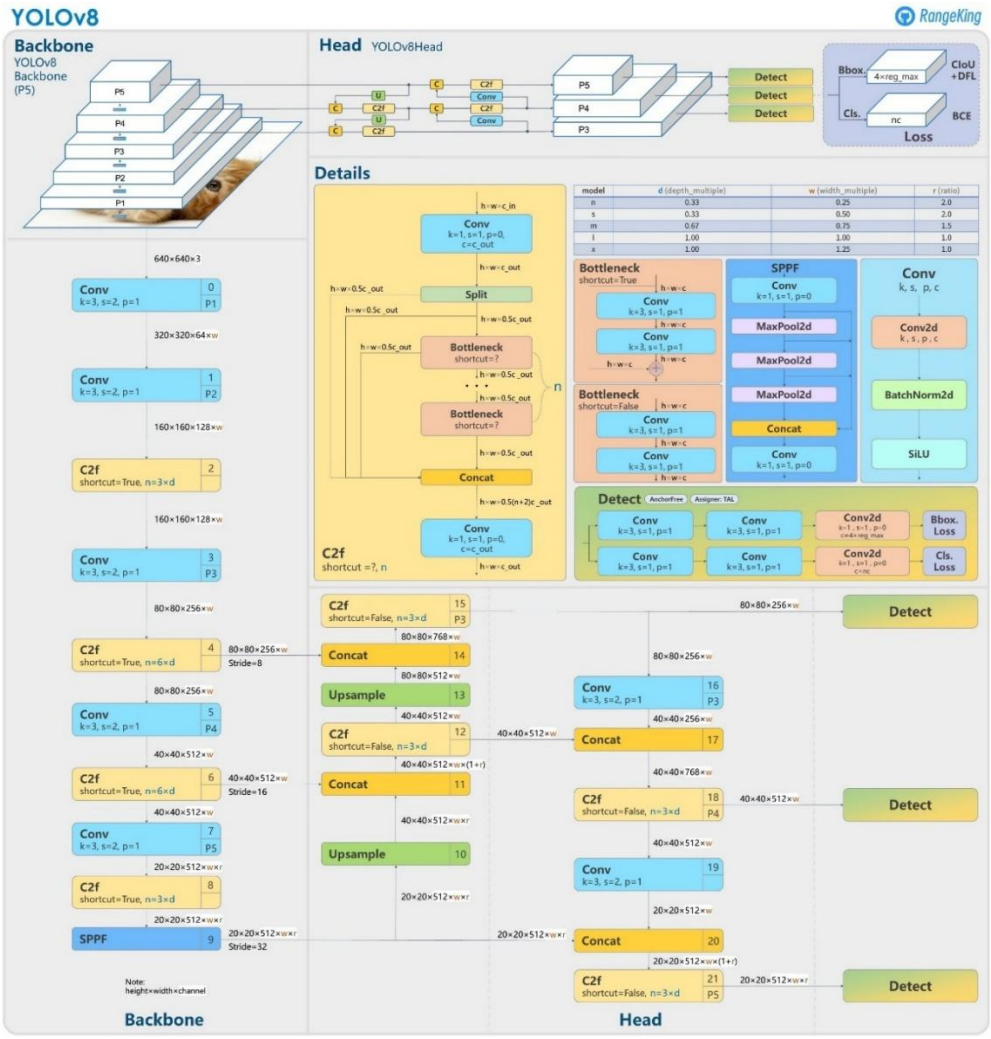


圖 3.29 YOLOv8 模型架構圖

在分割任務上，YOLOv8 引入 segmentation head，於每個偵測框預測一組對應的遮罩向量，並與共享特徵圖進行乘積，最終輸出對應之 instance-level mask。該設計兼顧物件定位與像素級分割精度，特別適用於需要即時處理的大型醫學影像資料集。本研究中即採用 YOLOv8 進行腦部 MRI 影像中腫瘤區域的實例分割，實驗證實其能有效辨識明顯腫瘤區域，並具備優異的推論速度與運算效率。

(2) YOLOv11

YOLOv11 為 YOLO 系列在 2024 年後進一步演進的版本，雖尚未於正式期刊發表，但已於多項開源平台與競賽中展現優異性能。相較於 YOLOv8，YOLOv11 延續 anchor-free 架構基礎，並融合多項現代視覺模型技術進行升級。其主幹網路採用 RepViT 或 MobileOne 模組，以提升特徵擷取效率並強化在不同硬體平台上的部署效能[90]；同時，模型中也加入類似 Transformer 的全域建模結構，例如 EMA（Exponential Moving Average attention）與 SPPF++ 等模組，以強化上下文語意理解能力。此外，在分割任務方面，YOLOv11 進一步優化了 segmentation head 的解碼流程與遮罩生成機制，提升遮罩邊界的解析度與預測精度，使模型更能勝任於高解析度醫學影像中進行腫瘤區域的像素級辨識。

YOLOv11 在實例分割任務中的邊界擷取與微小目標辨識能力相較 YOLOv8 有明顯提升，特別在高分辨率 MRI 腦部影像中對於邊緣模糊或腫瘤輪廓不清的情境，能夠提供更細緻的分割結果[91]。

本研究中同步使用 YOLOv8 與 YOLOv11 於相同資料集上進行訓練與評估，藉以比較其於不同腫瘤大小與位置條件下之實例分割表現，並觀察其在醫學影像應用場景中的實用性與可擴展性。

3.7.2 Swin-Unet

Swin-Unet 為一種融合 Transformer 與 U-Net 架構優勢的影像分割模型，由 Cao 等人於 2021 年提出，專為醫學影像分割任務設計[87]。其主要特點在於採用 Swin Transformer 作為編碼器，透過區域性視窗內部之自注意力機制（Window-based Multi-head Self Attention, W-MSA），結合滑動視窗策略（Shifted Windows），實現高效之全域語意資訊建模。相較於傳統全域 attention 方法，Swin Transformer 在維持空間一致性與運算效率上更具彈性，特別適合高解析度醫學影像處理。

Swin-Unet 繼承 U-Net 架構中的對稱式編碼與解碼路徑設計，並於解碼器中引入跳接連接（skip connection），用以保留低階空間細節資訊。整體架構由四層 Swin Transformer block 組成的編碼器與對應解碼器所構成，中間再透過 patch merging 與 expanding 模組進行特徵圖解析度轉換。此外，該模型捨棄傳統 CNN 的卷積運算，全面以 Transformer 操作為主，使得特徵提取過程更具長距依賴特性，提升模型在邊界模糊與異質性病灶的分割能力。

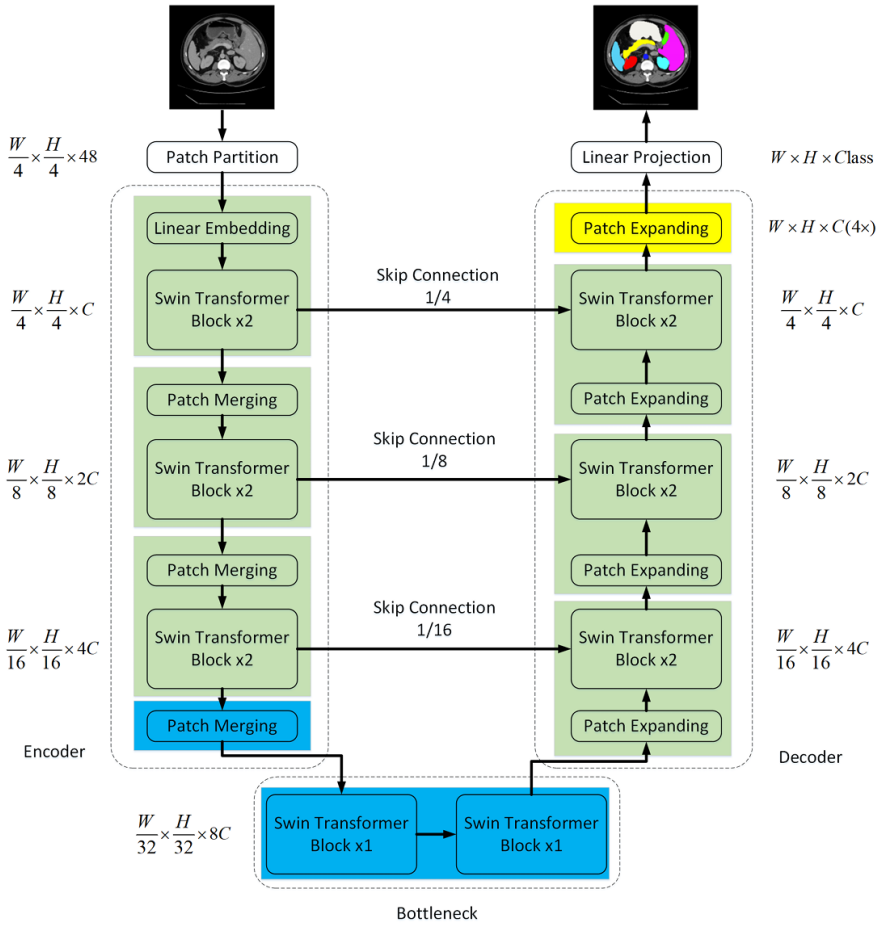


圖 3.30 Swin-Unet 模型架構圖[87]

3.7.3 Mask R-CNN

Mask R-CNN 為 He 等人於 2017 年提出之兩階段實例分割架構，基於 Faster R-CNN 擴充而成，具備同時進行物件偵測與像素級遮罩預測的能力[69]。該架構第一階段利用區域建議網路（Region Proposal Network, RPN）擷取潛在的目標候選區域（Region of Interests, RoIs），第二階段則針對每個 RoI 執行分類、邊界框迴歸與遮罩生成三項任務。與語意分割模型僅區分類別不同，Mask R-CNN 可進一步針對每一個實體進行分離式分割（instance-level segmentation），特別適合處理多病灶或空間分布複雜之醫學影像資料。

在模型架構上，Mask R-CNN 於原有的 Faster R-CNN 架構中額外加入一條平行的遮罩預測分支（mask branch），以全卷積網路（Fully Convolutional Network, FCN）實作，直接產生固定尺寸的二值遮罩，對應至每個 RoI 區域。此分支與分類與定位任務獨立進行，透過多任務損失函數共同優化，兼顧分類準確度與遮罩品質。為強化對多尺度目標的辨識能力，後續研究普遍在原始架構中整合特徵金字塔網路（Feature Pyramid Network, FPN），以促進不同解析度間的特徵融合與上下文理解。

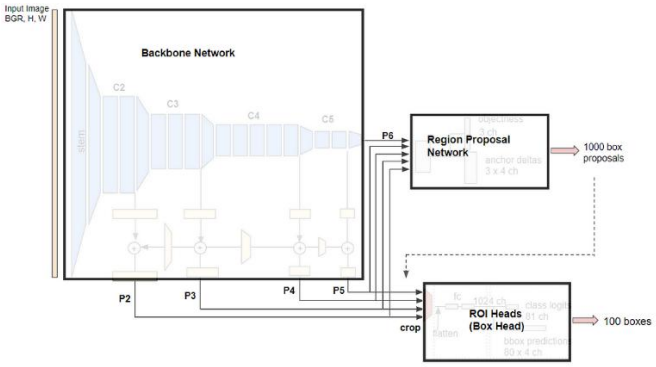


圖 3.31 Mask R-CNN 模型架構示意圖[92]

本研究所使用之 Mask R-CNN 模型採用 ResNet-50 為骨幹網路，其為具 50 層深度之殘差神經網路架構，具備穩定的特徵提取能力與參數效率；並結合 FPN 進行多尺度特徵融合，以提升模型對不同大小腫瘤區域的辨識能力。此改良型架構使模型在面對高解析度醫學影像時，能同時保留細部邊界與全域語意脈絡，為腦部腫瘤分割任務提供有力支撐。

本研究中，儘管 Mask R-CNN 原為實例分割架構，設計上適用於多實體目標之像素級辨識，但由於本研究所使用之 MRI 影像皆僅包含單一腫瘤區域，且未涉及不同實例間之辨識與區隔，因此以語意遮罩（semantic mask）作為訓練監督信號已足以提供模型所需之空間與語意資訊。在此情境下，語意遮罩可簡化標註流程，同時保留必要的區域輪廓資訊，適用於模型訓練與推論階段之精準分割任務。

3.8 模型驗證與評估指標

為全面評估本研究所建立之深度學習模型於分類與分割任務中的效能，分別採用多項指標進行性能量化。對於分類模型，透過混淆矩陣（confusion matrix）所延伸之常用指標進行評估，包括準確率（Accuracy）、精確率（Precision）、召回率（Recall）、F1 分數（F1-score）與曲線下面積（Area Under the Curve, AUC），其中 Precision、Recall 與 F1-score 均採用 macro-averaging 方法進行計算，以平均衡量各類別之表現，減少資料不平衡所造成的評估偏差。針對語意分割與實例分割任務，則採用交集聯集比（Intersection over Union, IoU）與 Dice 相關係數（Dice Similarity Coefficient, DSC）作為主要評估指標，並額外透過像素層級計算遮罩預測結果的 Precision 與 Recall，以進一步分析模型對腫瘤區域的判斷準確性與涵蓋能力。

3.8.1 影像分類結果評估

(1) 混淆矩陣（Confusion Matrix）

混淆矩陣是一種常用於分類任務的性能分析工具，能直觀呈現模型在預測過程中各類別之間的分類情形。其矩陣結構通常包含四個要素：真正例（True Positive, TP）、假正例（False Positive, FP）、真負例（True Negative, TN）、假負例（False Negative, FN），分別代表模型對正、負類別的正確與錯誤預測。透過混淆矩陣可進一步計算多種分類評估指標，協助判斷模型在不同類別上的表現與錯誤類型。

		Actual Values		
		Positive	Negative	
Predictive Values	Positive	True Positive (TP)	False Positive (FP)	**Precision** $\frac{TP}{TP+FP}$
	Negative	False Negative (FN)	True Negative (TN)	**F1 Score** $\frac{2 \cdot Precision \cdot Recall}{Precision+Recall}$
		Recall $\frac{TP}{TP+FN}$	**Specificity** $\frac{TN}{FP+TN}$	**Accuracy** $\frac{TP+TN}{TP+FP+FN+TN}$

圖 3.32 混淆矩陣

(2) 準確率（Accuracy）

準確率是最基本的分類評估指標，用以衡量模型整體預測的正確程度，公式如下公式 11。其定義為所有正確預測樣本數（$TP + TN$）除以總樣本數（$TP + FP + TN + FN$）。Accuracy 數值愈高，代表模型整體判斷能力愈佳。然而，在資料分布不均的情況下，Accuracy 可能無法充分反映模型在各類別上的實際表現，因此常需搭配其他指標共同參考。

$$Accuracy = \frac{TP + TN}{TP + FP + TN + FN} \tag{11}$$

(3) 精確率（Precision）

精確率衡量模型預測為正例樣本中，實際正確的比例，計算公式如公式 12。該指標特別適用於錯誤分類為正類會造成嚴重後果的情境，例如在醫學診斷中，錯將健康個體判為患病可能導致不必要的進一步檢查，因此需確保正類預測的可靠性。高 Precision 意味著模型在做出正類預測時，多數為正確結果。

$$Precision = \frac{TP}{TP + FP} \tag{12}$$

(4) 召回率（Recall）

召回率表示在所有實際為正例的樣本中，被模型成功辨識出的比例，公式為公式 13。此指標反映模型對於正例樣本的涵蓋能力，在腫瘤偵測等醫療應用中尤為重要，因為如漏判（False Negative）可能導致延誤診斷。Recall 值越高表示模型越少遺漏真正的正例樣本。

$$Recall = \frac{TP}{TP + FN} \tag{13}$$

(5) F1 分數（F1-Score）

F1 分數為精確率與召回率的調和平均，計算公式如公式 14，用以綜合評估模型在正例預測中的精確性與完整性。F1-score 適用於樣本不平衡的情況，能有效平衡 Precision 與 Recall，數值愈高表示模型整體表現越佳。特別是在醫學分類任務中，F1-score 可作為判斷模型實用性的重要指標之一。

$$F1-Score = 2 \times \frac{(Precision \times Recall)}{Precision + Recall} \tag{14}$$

(6) 曲線下面積（Area Under Curve）

AUC 通常指 ROC 曲線（接收者操作特徵曲線）下的面積，用以衡量模型對正負例區分的能力。ROC 曲線描繪在不同閾值下的假陽率(FPR)與真陽率(TPR)之間的關係，而 AUC 則為該曲線與橫軸之間的總面積，數值範圍介於 0 與 1 之間。AUC 越接近 1，代表模型越能有效區分不同類別；若為 0.5，則表示模型表現等同於隨機猜測。

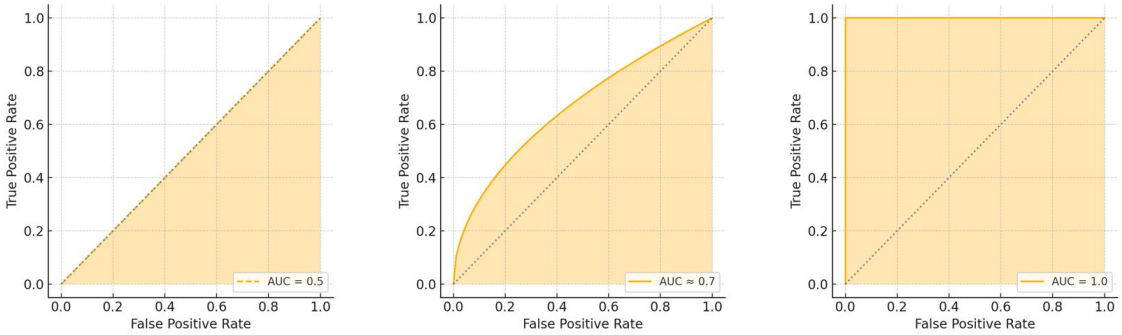


圖 3.33 AUC 比較示意圖

3.8.2 影像分割結果評估

(1) 精確率（Precision）

精確率在影像分割任務中用以衡量模型預測出的正類像素中，有多少實際屬於正確區域。其計算方式為正確預測的正類像素數（True Positive）除以預測為正類的總像素數（True Positive + False Positive），公式如公式 15 所示。該指標特別適用於錯誤標註為病灶區域會導致後續醫療誤判的情境，例如將正常組織誤判為腫瘤區域，可能造成臨床上不必要的診斷或治療。高 Precision 表示模型在產生正類遮罩時具有高度可靠性，預測出的腫瘤區域大多為真實存在的病灶。

$$Precision = \frac{TP}{TP + FP} \tag{15}$$

(2) 召回率（Recall）

召回率在影像分割任務中，用以衡量模型對實際正類區域的涵蓋能力。其定義為正確預測的正類像素數（True Positive）除以所有實際為正類的像素總數（True Positive + False Negative），如公式 16 所示。該指標特別反映模型對病灶區域的偵測完整性，對於臨床應用中如腫瘤分割等任務尤為關鍵。若模型未能成功標註病灶區域，即產生漏判（False Negative），可能導致病灶未被發現而延誤診斷。因此，Recall 值越高，代表模型對實際病灶區域的偵測越完整，遺漏率越低。

$$Recall = \frac{TP}{TP + FN} \tag{16}$$

(3) 交集聯集比（Intersection over Union, IoU）

IoU 為語意分割與目標檢測任務中的常用指標，用以評估預測區域與實際標註區域之間的重疊程度。其定義為兩者交集（Intersection）面積除以聯集（Union）面積，如公式 17。IoU 數值愈高，代表模型預測的區域與真實腫瘤位置越接近。IoU 能有效反映模型空間定位的準確性，在醫學影像中常用於評估腫瘤分割或偵測之準確程度。

$$IoU = \frac{A_{\text{Intersection}}}{A_{Union}} \tag{17}$$

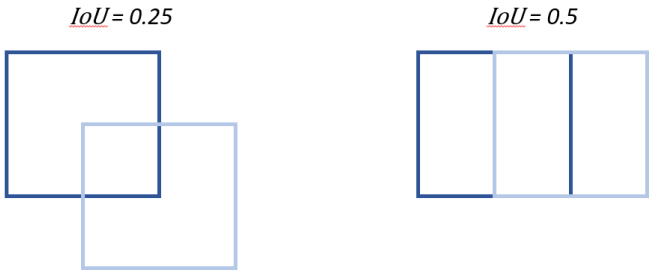


圖 3.34 IoU 示意圖

(4) Dice 相關係數（Dice Similarity Coefficient, DSC）

Dice 係數是另一常見的影像分割評估指標，與 IoU 類似，同樣用來量化預測遮罩與實際標註遮罩的重疊程度。計算方式如公式 18，其中 A 與 B 分別代表預測與實際的區域。Dice 係數對小型區域特別敏感，能更準確反映小腫瘤或不規則區塊的分割效果，因此在醫學影像應用中具有高度實用性。數值越高代表模型分割效果越佳。

$$DSC = \frac{2 \times |A \cap B|}{|A + B|} \tag{18}$$

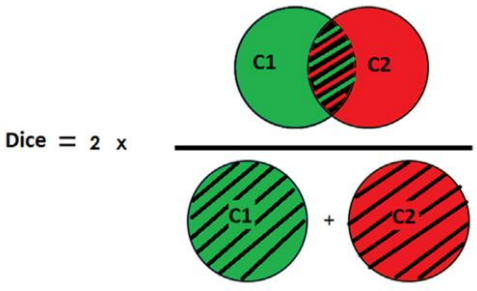


圖 3.35 DSC 示意圖[93]

3.9 圖形化使用者介面設計

為提升本研究模型於臨床實務中的應用效能與操作便利性，特別設計一套具備互動功能的圖形化使用者介面（Graphical User Interface, GUI）。本系統以 Python 為主要開發語言，並採用 Streamlit 框架進行前端建構，具備輕量、易部署與高度整合性等優點。GUI 的設計目標在於提供一個直觀且無需撰寫程式碼的操作環境，使醫療人員能以最少的技術門檻，即可完成 MRI 影像的上傳、模型推論以及結果檢視等步驟，進而提升診斷流程的效率與一致性。

該介面整合了影像上傳、模型推論與結果展示等模組。使用者首先透過介面上傳單張 MRI 影像，系統會自動接收該輸入並導入經 5-fold 交叉驗證訓練之 Stacking 集成分類模型，以判斷其腫瘤所屬類別。完成分類後，影像會接續送入預先訓練之 YOLOv8 分割模型，用以標記出腫瘤所在位置。

最後，系統會於介面上同步顯示模型預測的分類結果與對應的腫瘤遮罩，協助使用者迅速掌握診斷資訊與腫瘤分布，進一步提升醫療判讀效率與輔助決策的實用性。

第 4 章　實驗結果與討論

4.1　實驗流程

本研究整體實驗流程如圖 4.1 所示，首先使用包含三種腦部腫瘤類型（膠質母細胞瘤、腦膜瘤、腦下垂體瘤）的 MRI 影像訓練資料，分別輸入至兩類模型進行處理：分類模型與分割模型。分類任務採用多種主流架構，包括 ResNet、EfficientNet、Swin Transformer、Vision Transformer、PiT、EfficientNetV2、EfficientFormer 與 ResNeSt，進行腫瘤類別的判別；分割任務則選用 YOLOv8、YOLOv11、Swin U-Net 與 Mask R-CNN 等模型，以預測腫瘤區域並產生對應的遮罩圖（segmentation mask）。

為客觀評估模型表現，本研究針對使用測試資料對分類與分割結果分別採用多項指標進行量化分析。分類模型以 Accuracy、Precision、Recall、Specificity、F1-score 及 AUC 作為評估指標，評估後再挑選出表現最好的三個模型進行集成學習，並透過相同的指標再次評估集成後的結果；分割模型則使用 IoU 與 Dice Score 衡量分割品質。除量化指標外，亦運用 Grad-CAM 技術產生熱區圖，觀察分類模型在進行判斷時所聚焦的影像區域，作為模型解釋性的輔助工具；同時將分割模型所產生的預測遮罩與原始影像進行對比，以輔助理解分割效果與實際病灶位置之關聯性。接下來將依據此流程，逐步說明各模型於不同任務下的實驗結果與分析。

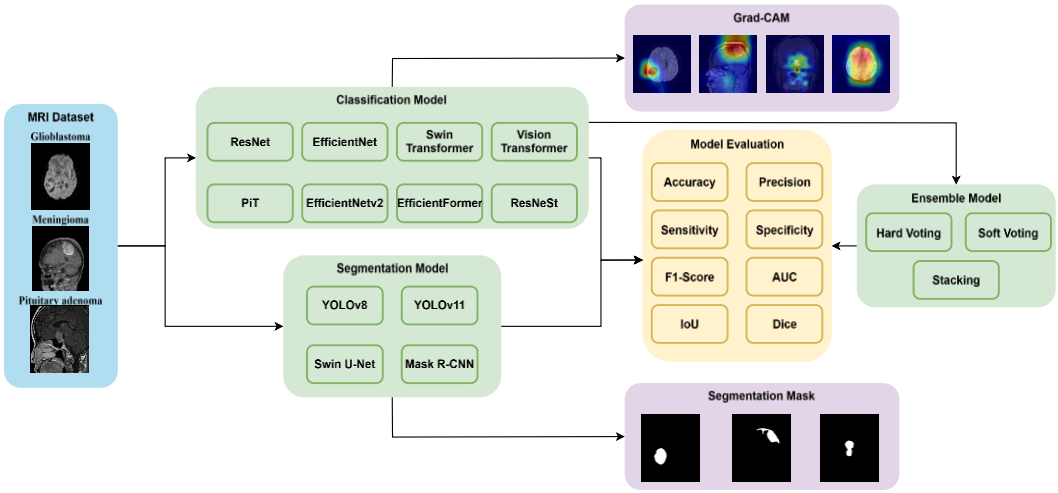


圖 4.1 實驗流程圖

4.2 實驗環境配置與模型訓練參數

為確保模型訓練與評估過程具備良好的效能與穩定性，本研究於高效能運算環境中進行所有實驗，相關硬體與軟體配置詳列於表 4.1。實驗中採用之深度學習模型包含影像分類與影像分割兩大類，並針對不同模型特性調整其訓練參數以獲得最佳效能。分類模型所使用之訓練批次大小（batch size）、學習率（learning rate）、訓練週期數（epochs）、優化器（optimizer）與影像輸入尺寸等設定如表 4.2 所示；影像分割模型之訓練參數則整理於表 4.3，涵蓋 YOLOv8、YOLOv11、Swin-Unet 與 Mask R-CNN 等架構，說明其訓練過程之配置差異與考量。

表 4.1 實驗環境配置表

OS	Windows 10 x64
CPU	13th Gen Intel(R) Core(TM) i7-13700K, 3.40 GHz
GPU	NVIDIA GeForce RTX 4090
DRAM	128 GB
CUDA	12.4
Python	3.8.20
Pytorch	2.4.0
Torchvision	0.19.0
Tensorflow	2.11.0
Pillow	9.5.0

表 4.2 所列之各項訓練參數，係綜合文獻參考、預先試驗結果及硬體資源限制後所決定。Batch size 是經過測試發現 64 在本研究 GPU 記憶體容量下能兼顧穩定訓練與合理運算時間，故選定為最終值。Epochs 則參考相關 MRI 影像分類研究常用範圍，並經試驗確認於 100 個 Epochs 內模型收斂且無顯著過擬合，因此固定為 100。學習率（Learning rate）以 0.001 為初始值，係依據 Adam 優化器於影像分類任務中的常用設定，並在預試驗中取得穩定收斂效果。優化器方面，選用 Adam 主要考量其自適應學習率機制，能在特徵分佈差異較大的多類別 MRI 資料中提供較佳的訓練穩定性。影像輸入尺寸則依模型架構需求與原論文設定為基準，大多數模型採用 (224, 224) 以符合主流分類骨幹網路設計，Swin Transformer 則選擇 (256, 256) 以配合其視窗切分策略，提升特徵提取效率。透過上述設定，可在確保訓練條件一致的同時，最大化各模型的效能表現，並提供公平的比較基準。

表 4.2 分類模型參數配置表

Model	Batch size	Epochs	Learning rate	Optimizer	Input size
ResNet50	64	100	0.001	Adam	(224,224)
EfficientNet_b0	64	100	0.001	Adam	(224,224)
Vision Transformer	64	100	0.001	Adam	(224,224)
Swin Transformer V2	64	100	0.001	Adam	(256,256)
PiT	64	100	0.001	Adam	(224,224)
EfficientNet V2	64	100	0.001	Adam	(224,224)
EfficientFormer	64	100	0.001	Adam	(224,224)
ResNeSt50	64	100	0.001	Adam	(224,224)

表 4.3 彙整本研究所採用之影像分割模型及其訓練參數設定。各項參數綜合文獻依據、預先試驗結果與硬體資源限制後所決定，並依模型架構特性與任務需求進行調整，以達成最佳分割表現。YOLO 系列模型屬於輕量化且強調即時性的分割架構，經測試 batch size 為 16 時可在 GPU 記憶體限制內維持穩定訓練，同時搭配較大的輸入尺寸 (640×640) 以獲取更完整的空間特徵，並參考官方建議與預試驗結果將學習率設定為 0.001、優化器選擇 AdamW，並於 200 個 Epochs 內達成收斂。Swin-Unet 結合 Transformer 與 U-Net 架構，經測試發現 (128×128) 的輸入尺寸可兼顧特徵細節與計算效率，並以較小的學習率 (0.0001) 提升邊界偵測的穩定性與精度。Mask R-CNN 作為實例分割架構，依其原始文獻與常用設定採用 SGD 優化器與 0.02 的學習率，並在預試驗中確認延長至 250 個 Epochs 可有效提升遮罩預測精度。整體而言，各模型的訓練設定皆為在確保收斂與效能的前提下，平衡計算負載與精度需求，並提供公平的一致性比較基準。

表 4.3 影像分割模型參數配置表

Model	Batch size	Epochs	Learning rate	Optimizer	Input size
YOLO v8	16	200	0.001	AdamW	(640,640)
YOLO v11	16	200	0.001	AdamW	(640,640)
Swin Unet	64	200	0.0001	Adam	(128,128)
Mask R-CNN	64	250	0.02	SGD	(256,256)

4.3 影像分類模型結果比較

4.3.1 模型訓練結果比較

在資料尚未進行增量處理前，各模型在測試集上的分類表現呈現出明顯差異。ResNeSt50d 為表現最佳者，其在所有評估指標上皆為最高，Recall 達到 0.7396，AUC 為 0.8726，此結果可歸因於其融合 Split-Attention 模組與深層殘差架構的設計，強化了模型在有限資料下的特徵辨識能力與泛化能力。而 ResNet50 與 EfficientFormer 亦表現穩定，皆能在 Precision、Recall 及 AUC 指標上維持一定水準。EfficientFormer 作為結合 CNN 與 Transformer 的混合式架構，其引入卷積分支與 token permutation 機制，使其在中小型資料集上能有效捕捉區域特徵。

相較之下，純 Transformer 架構的 Vision Transformer、Swin Transformer 與混和架構 PiT 表現較為受限。Vision Transformer 的 Precision 僅為 0.0931，F1-Score 為 0.1357，顯示其在資料量不足或未經資料增強的情況下，難以穩定學習特徵。Swin Transformer 與 PiT 引入區域注意力與階層設計雖略有改善，但整體表現仍低於多數 CNN 架構。EfficientNet 系列的兩個模型中，雖然擁有良好的模型規模與運算效率平衡設計，但在本階段資料條件下，其學習效果欠佳，這些模型的潛力仍待經過資料處理後能夠加以發揮。

表 4.4 增量前分類模型結果比較表

Model	Accuracy	Precision	Recall	F1-Score	AUC
ResNet50	0.6321	0.6541	0.6895	0.6584	0.8601
EfficientNet_b0	0.5708	0.5931	0.6031	0.5958	0.8280
Vision Transformer	0.3726	0.0931	0.2500	0.1357	0.6374
Swin Transformer V2	0.4387	0.4459	0.4876	0.4559	0.7416
PiT	0.4528	0.4077	0.5455	0.4509	0.7763
EfficientNet V2	0.4953	0.5883	0.5848	0.4963	0.8038
EfficientFormer	0.6226	0.6458	0.6897	0.6489	0.8559
ResNeSt50	0.6745	0.6957	0.7396	0.6923	0.8726

進行資料增量後，各模型在測試集上的分類效能皆顯著提升，整體表現趨於集中且穩定。ResNet50 達到最高準確率（0.9097）與 F1-Score（0.9125），顯示其殘差網路架構能有效吸收經增量處理後的資訊，提升深層特徵學習效率。ResNeSt50d 與 EfficientNet V2 同樣有優異表現，反映其架構對於複雜分類邊界的辨識能力具高適應性。ResNeSt50d 透過多分支特徵重組機制，有助於提升多類別區分能力；而 EfficientNet V2 的 stage-wise scaling 與改良型 MBConv 設計，有效利用空間結構特徵進行分類。

此外，EfficientFormer 與 EfficientNet_b0 亦呈現穩定表現，皆達成超過 0.8 的 F1-Score，說明這兩種計算資源友善的架構在配合適當的資料增量後仍具應用價值。PiT 與 Swin Transformer 在 Precision 與 Recall 上表現均衡，顯示其層級式注意力設計對於特徵學習具一定助益。Vision Transformer 雖仍低於其他模型，但 Precision 提升至 0.5907，顯示資料增量有幫助改善其全域注意力訓練過程中的不穩定性，提升模型對關鍵特徵的識別能力。

表 4.5 增量後分類模型結果比較表

Model	Accuracy	Precision	Recall	F1-Score	AUC
ResNet50	0.9097	0.9132	0.9121	0.9125	0.9867
EfficientNet_b0	0.8195	0.8265	0.8296	0.8275	0.9539
Vision Transformer	0.5731	0.5907	0.6297	0.5743	0.8187
Swin Transformer V2	0.6647	0.6760	0.6903	0.6807	0.8831
PiT	0.6905	0.6955	0.7428	0.7015	0.8975
EfficientNet V2	0.8575	0.8689	0.8619	0.8652	0.9668
EfficientFormer	0.7951	0.8018	0.8077	0.8041	0.9449
ResNeSt50	0.8789	0.8772	0.8891	0.8820	0.9796

4.3.2 分類模型可解釋性分析

在完成分類模型效能評估後，本研究進一步探討模型在分類決策上的可解釋性。為此，本研究選擇了在資料增量後分類表現最優異的三種模型—ResNet50、ResNeSt50d 與 EfficientNetV2-S，進行可視化分析。透過 Grad-CAM（Gradient-weighted Class Activation Mapping）技術，能夠呈現模型在進行判別時所關注的影像區域，進一步驗證模型是否聚焦於與病灶相關的腦部結構區域，藉此提升結果的可信度與醫學意義。接下來將針對這三種模型產生的 Grad-CAM 圖像進行深入解讀與比較。

表 4.6 顯示 ResNet 模型在四種不同類別的腦部影像上所產生的 Grad-CAM 可視化結果。在膠質母細胞瘤（Glioblastoma）影像中，模型聚焦於腦部左側區域，該位置與實際腫瘤所在區域有空間上的重疊。腦膜瘤（Meningioma）樣本中，Grad-CAM 熱區主要分布於顱側靠近病灶的部位，包含了腫瘤本體及延伸至硬腦膜的尾端區域，顯示模型可能對此類典型的腫瘤徵象具有一定辨識能力。對於腦下垂體腺瘤（Pituitary Adenoma），模型的關注區域分布較為分散，涵蓋蝶鞍（sella turcica）、腦底中線及周邊顱內結構，整體聚焦能力略顯不足，顯示模型在此類型腫瘤的定位上可能存在不確定性。正常樣本中則未觀察到聚焦於特定異常區域的反應，注意力分布相對分散。

表 4.6 ResNet 模型 Grad-CAM 表

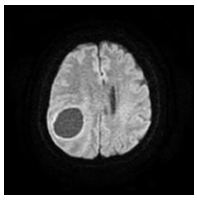
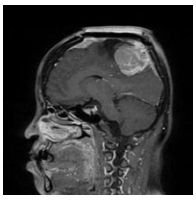
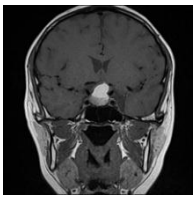
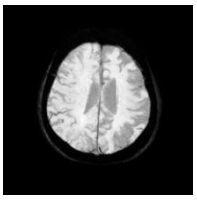
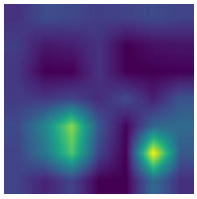
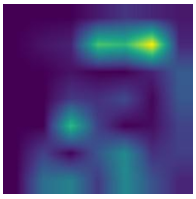
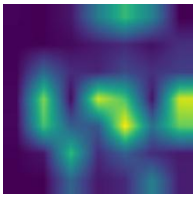
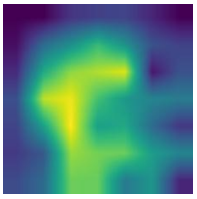
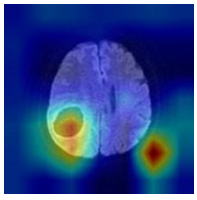
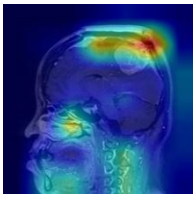
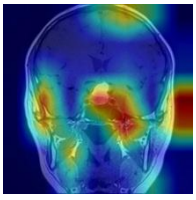
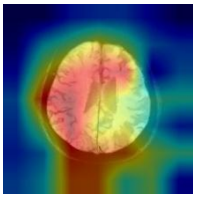
	Glioblastoma	**Meningioma**	**Pituitary Adenoma**	**Normal**
Original				
Grad-CAM				
Overlay				

表 4.7 展示 ResNeSt 模型於四類腦部影像中的 Grad-CAM 可視化結果。針對膠質母細胞瘤（Glioblastoma），模型所產生的熱區高度集中，並位於腦部左側腫瘤病灶位置，顯示其對該區域具明確的空間聚焦能力。於腦膜瘤（Meningioma）影像中，關注區域涵蓋顱頂部腫瘤結構，並延伸至鄰近硬腦膜的附著處，包含腫瘤本體與可能的 dural tail 區段，呈現出一定程度的病灶結構辨識能力。在腦下垂體腺瘤（Pituitary Adenoma）樣本中，Grad-CAM 熱點主要分布於蝶鞍（sella turcica）及其周圍結構，包括視交叉與腦底部中線區域；此外，模型亦對腫瘤下方的低訊號空洞產生關注，該區域推測為蝶竇（sphenoid sinus）等氣室結構，顯示模型可能對顱底空間變化有所反應。正常影像中則未觀察到聚焦於特定異常區域的現象，注意力分布較為均勻。整體而言，ResNeSt 模型於不同病變類型中展現出對解剖位置具有一致性的關注趨勢，顯示其具備一定程度的分類決策可解釋性。

表 4.7 ResNeSt 模型 Grad-CAM 表

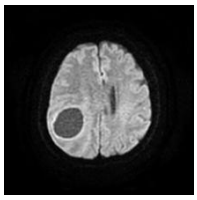
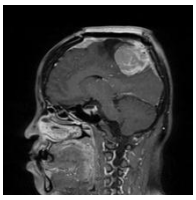
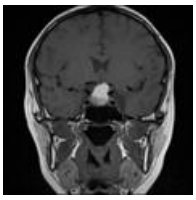
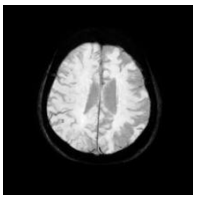
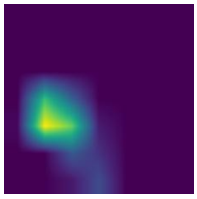
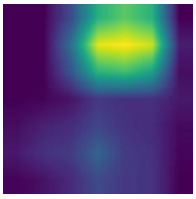
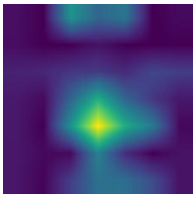
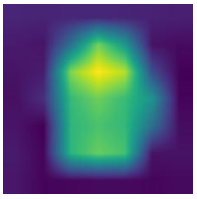
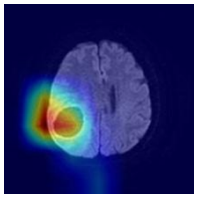
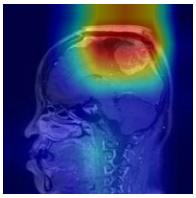
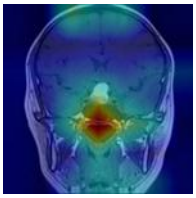
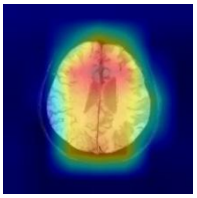
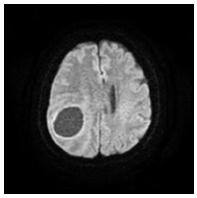
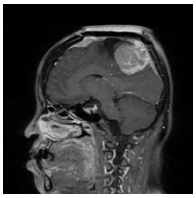
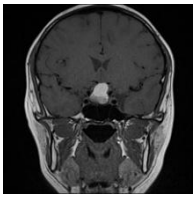
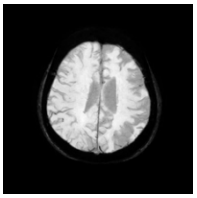
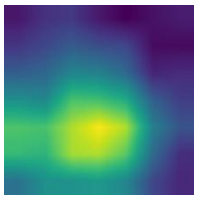
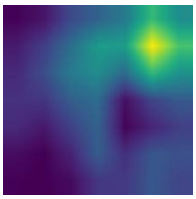
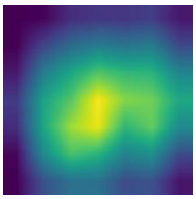
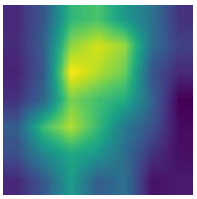
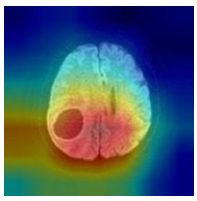
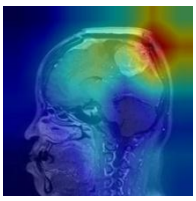
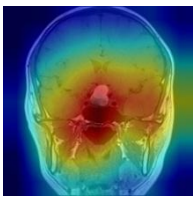
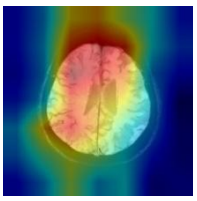
	Glioblastoma	**Meningioma**	**Pituitary Adenoma**	**Normal**
Original				
Grad-CAM				
Overlay				

表 4.8 呈現 EfficientNetV2 模型在四類腦部影像上的 Grad-CAM 可視化結果。就膠質母細胞瘤（Glioblastoma）而言，模型將注意力集中於病灶所在的左側腦葉區域，熱區聚焦明確，與腫瘤實際分布具有良好對應性。於腦膜瘤（Meningioma）影像中，Grad-CAM 熱區位於顱頂部腫瘤區域，呈現局部擴散，展現一定的結構辨識能力。對於腦下垂體腺瘤（Pituitary Adenoma），模型熱區涵蓋蝶鞍（sella turcica）與顱底中線，並延伸至下方的蝶竇（sphenoid sinus）與周邊顱內區域，顯示其不僅關注腫瘤本體，也同時對其他非病灶區域產生反應。與前述兩個模型相比，EfficientNetV2 的注意力分布更為廣泛，聚焦範圍較大，雖涵蓋腫瘤相關結構，但定位相對不夠集中。正常樣本中則未觀察到聚焦於特定異常區域的反應，注意力呈現中線擴散分布，反映模型在無病灶條件下之自然關注趨勢。

表 4.8 EfficientNetV2 模型 Grad-CAM 表

	Glioblastoma	**Meningioma**	**Pituitary Adenoma**	**Normal**
Original				
Grad-CAM				
Overlay				

綜合三種模型的 Grad-CAM 結果可觀察到，雖然各模型皆能在不同程度上將注意力聚焦於腫瘤相關的解剖結構，但其表現仍存有差異。ResNet 模型整體聚焦較為穩定，於各病變類型中皆能對應至病灶區域，且於腦膜瘤與腦下垂體腺瘤的定位結果呈現出解剖結構上的合理性。ResNeSt 則進一步展現出對病灶邊界與附屬結構的較細緻辨識能力，注意力集中且與病灶一致性高。相較之下，EfficientNetV2 雖能大致覆蓋腫瘤區域，但熱區分布相對分散，且於正常樣本中產生較多非特異性聚焦，顯示其在模型判斷過程中可能涉及較多冗餘資訊，影響解釋一致性。整體而言，ResNeSt 的可視化結果最能反映與實際病灶位置的對應關係，而 ResNet 則具穩定性，EfficientNetV2 雖具一定反應能力，但聚焦精度與選擇性尚有優化空間。

4.4 集成學習分類結果比較

為提升分類模型在腦部腫瘤影像判別任務中的整體性能與穩定性，本研究採用集成學習策略，整合多個基礎模型的預測結果，以強化模型間的互補性。基礎模型方面，根據單一模型訓練階段的結果，選取分類表現最優異之三種模型—ResNet50、EfficientNetV2-S 與 ResNeSt50d 作為集成基礎。三種整合方法分別為：硬投票（Hard Voting）、軟投票（Soft Voting）與疊加法（Stacking）。

其中，Voting 方法分別根據類別標籤或預測機率進行多模型預測結果的整合；而 Stacking 方法則採用五折交叉驗證（5-Fold Cross-Validation）之模型驗證集預測 softmax 結果，產生次級訓練資料，並以隨機森林（Random Forest）作為次級分類器（meta-model），學習如何根據各模型的預測輸出進行最終判斷。

根據表 4.9 的結果，可觀察到三種集成學習方法在各項指標上展現出不同的表現，這些差異與各方法本身的運作原理密切相關。其中，Stacking 的五項指標皆為最高，顯示其整合策略具有最好的效果。由於 Stacking 並非僅對模型輸出進行合併，而是透過次級模型進一步學習各基礎模型的預測模式與相對貢獻，因此能有效捕捉不同模型間的互補關係與非線性特徵。這使得其在複雜樣本的判斷上更具靈活性，進而反映在 Precision（0.9740）與 Recall（0.9683）上的高分表現，並帶動 F1-Score（0.9710）與 AUC（0.9985）的提升。

Soft Voting 的整體表現雖略低於 Stacking，但 AUC（0.9941）仍明顯高於 Hard Voting，代表其在樣本區辨能力上具有優勢。此方法根據各模型的預測機率進行加總，有助於保留模型對樣本的信心程度，對於界限模糊或分類不確定的個案，能提供較細膩的判斷。因此在 Recall（0.9417）與 F1-Score（0.9444）上仍維持良好水準，反映其具備穩定且平衡的預測能力。

相較之下，Hard Voting 的各項指標均為最低，尤其在 Recall（0.9295）與 AUC（0.9524）落後最為明顯。由於其僅採用基礎模型的最終預測結果進行多數決，無法考量各模型的信心強度，因此在處理不確定或分歧樣本時，整合效果明顯受限。這樣的設計雖具實作簡便的優點，但在分類任務中往往難以取得最佳效果。

表 4.9 集成學習方法結果比較表

Model	Accuracy	Precision	Recall	F1-Score	AUC
Soft Voting	0.9419	0.9473	0.9417	0.9444	0.9941
Hard Voting	0.9298	0.9359	0.9295	0.9325	0.9524
Stacking	0.9699	0.9740	0.9683	0.9710	0.9985

4.5 影像分割模型結果比較

為評估本研究所使用之影像分割模型對腦部 MRI 腫瘤區域的遮罩預測能力，本節針對四種模型（YOLOv8、YOLOv11、Swin Unet、Mask R-CNN）進行實驗比較。各模型所評估之 Precision 與 Recall 為針對遮罩區域（mask）的像素層級評估，分別代表模型所預測的腫瘤區域中，有多少比例為實際正確（Precision），以及實際腫瘤區域中有多少被模型成功標記（Recall）。此外，也以常用之影像分割結果評估指標 Mean-IoU 與 Mean-Dice 進行整體分割效果的綜合評估，表格 4.7 與表格 4.8 分別整理增量前與增量後的實驗結果。

從表 4.11 可觀察到，在未進行資料增量處理的情況下，YOLOv8 在分割遮罩的 Precision 表現最佳，顯示模型對腫瘤區域的預測結果具有高可信度；而 YOLOv11 雖然 Precision 略低，但在 Mean-IoU 與 Mean-Dice 上略高於其他模型，代表其遮罩區域與實際標註的重疊程度更好。Swin Unet 則在 Recall 與 Dice 方面展現穩定性，適合捕捉腫瘤的整體區塊範圍；Mask R-CNN 雖具 mask 預測能力，但於本資料條件下其四項指標均為最低，整體分割表現略顯劣勢。

表 4.10 增量前分割效果比較表

Model	Precision	Recall	Mean-IoU	Mean-Dice
YOLOv8	0.9820	0.8670	0.8488	0.9087
YOLOv11	0.9770	0.8350	0.8630	0.9245
Swin Unet	0.8672	0.8523	0.8455	0.9008
Mask R-CNN	0.8494	0.8508	0.8047	0.8697

資料增量過後的分割結果如下表 4.8，四種模型的 mask 分割效能皆有明顯提升。YOLOv8 的 Precision 與 Recall 分別提升至 0.9920 與 0.9580，Mean-IoU 與 Mean-Dice 亦提升至 0.8980 與 0.9443，整體表現最為突出，顯示其具備強大的實例分割能力與對遮罩邊界的精確建模能力。YOLOv11 緊隨其後，各項指標接近 YOLOv8，尤其在 Mean-IoU（0.8968）上表現穩定。Swin Unet 在增量後的 Recall 提升至 0.9170，Dice 亦達 0.9415，展現其對於完整腫瘤區域的涵蓋能力。Mask R-CNN 亦呈現顯著進步，IoU 與 Dice 分別提升至 0.8673 與 0.9161，雖仍略低於其他模型，但整體已具實用價值。

表 4.11 增量後分割效果比較表

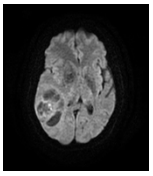
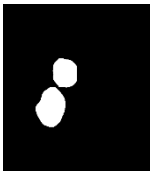
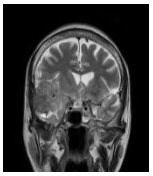
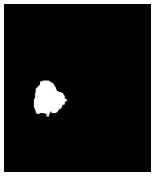
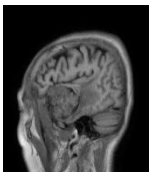
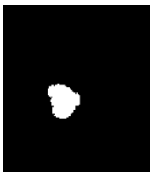
Model	Precision	Recall	Mean-IoU	Mean-Dice
YOLO v8	0.9920	0.9580	0.8980	0.9443
YOLO v11	0.9850	0.9230	0.8968	0.9431
Swin Unet	0.9029	0.9170	0.8685	0.9215
Mask R-CNN	0.9010	0.8828	0.8673	0.9161

為進一步比較各模型於不同腫瘤類型及影像視角下的實際分割表現，表 4.12 至表 4.14 分別展示了膠質母細胞瘤（Glioblastoma）、腦膜瘤（Meningioma）與腦下垂體瘤（Pituitary Adenoma）於三種軸向切面的 MRI 影像中，各分割模型所預測之遮罩結果與真實標註（Ground Truth）之對照。

在表 4.12 的膠質母細胞瘤影像中，YOLOv8 與 YOLOv11 在三種切面下皆能準確覆蓋腫瘤範圍，遮罩形狀緊貼實際邊界，反映其良好的空間對齊與穩定性；Swin-Unet 表現亦相當一致，惟在第一張圖的遮罩內部略有空洞現象；Mask R-CNN 則於部分切片產生額外區塊或遮罩斷裂，顯示在單一腫瘤實例中仍可能誤判為多個區域。

表 4.12 膠質母細胞瘤影像分割模型分割結果比較表

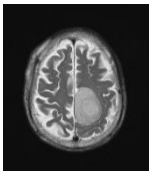
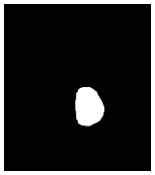
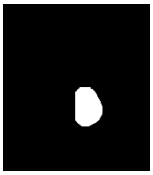
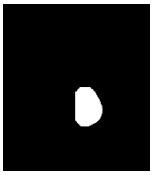
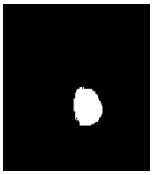
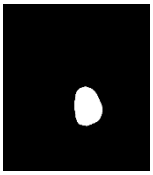
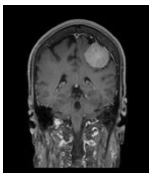
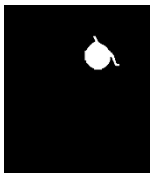
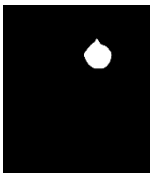
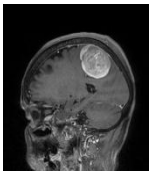
Glioblastoma

MRI Scan	Ground Truth	YOLO V8	YOLO V11	Swin U-Net	Mask R-CNN
					
					
					

於表 4.13 的腦膜瘤分割結果中，大多數模型在第一組軸向影像中均能良好重現腫瘤形狀，但在第二與第三列的橫斷與矢狀切面中，因腫瘤輪廓延伸較廣，Swin-Unet 與 Mask R-CNN 皆出現遮罩邊緣過度延伸與模糊化現象；YOLOv8 與 YOLOv11 則相對保守但仍貼合主要區塊，呈現較佳的結構一致性。

表 4.13 腦膜瘤影像分割模型分割結果比較表

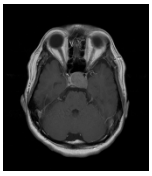
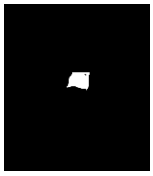
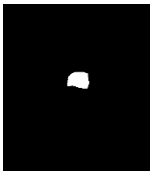
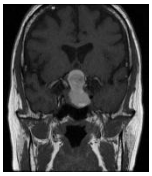
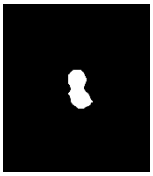
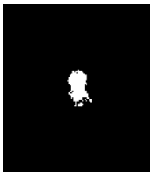
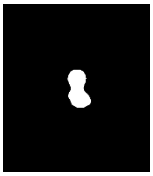
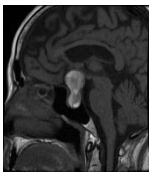
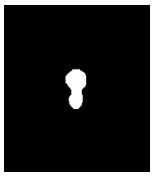
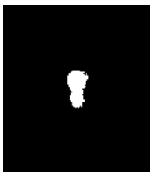
Meningioma

MRI Scan	Ground Truth	YOLO V8	YOLO V11	Swin U-Net	Mask R-CNN
					
					
					

針對表 4.14 中的腦下垂體瘤影像，由於腫瘤多位於蝶鞍中線位置且結構較小，對模型邊界解析能力提出更高挑戰。YOLOv8 與 YOLOv11 在三個方向上皆能準確擷取腫瘤區域，遮罩與 Ground Truth 高度重合；Swin-Unet 在第二張 coronal 切片中出現遮罩毛邊與多餘延伸，反映其對於細部控制仍略顯不足；Mask R-CNN 遮罩則普遍偏小或邊界不清，推測在面對小型腫瘤或中線結構時表現相對不穩定。

表 4.14 腦下垂體瘤影像分割模型分割結果比較表

Pituitary Adenoma

MRI Scan	Ground Truth	YOLO V8	YOLO V11	Swin U-Net	Mask R-CNN
					
					
					

綜上所述，可視化結果進一步驗證模型評估指標所呈現的趨勢。整體上 YOLOv8 與 YOLOv11 整體分割效果最為穩定，Swin-Unet 仍存在分裂與模糊的潛在問題，而 Mask R-CNN 雖具實例區隔能力，但在本研究的單一腫瘤遮罩任務中對邊界輪廓仍有一定誤差。

4.6 圖形化介面展示與操作結果

本研究設計之圖形化使用者介面（Graphic User Interface , GUI）整合分類與分割模型，提供清晰且具互動性的操作流程。圖 4.2 與圖 4.3 分別展示系統於影像上傳與預測完成階段的畫面。

如圖 4.2 所示，使用者透過介面上傳一張腦部 MRI 影像後，畫面左側即時呈現所選影像預覽，並於右方顯示「執行診斷」按鈕，供使用者確認影像無誤後手動啟動模型推論流程。此設計保留人工確認步驟，避免錯誤資料自動導入模型，亦提升整體操作的可控性。

當使用者點擊診斷按鈕後，系統會自動依序執行 Stacking 集成分類模型與 YOLOv8 分割模型。圖 4.3 為預測完成後的畫面，左側保留原始影像，右側顯示分割結果，紅色遮罩標示模型所判斷之腫瘤區域；下方同步顯示分類結果，以綠色區域顯示於畫面中。該介面整合推論流程並提供即時回饋，提升醫師判讀效率與臨床應用的實用性。

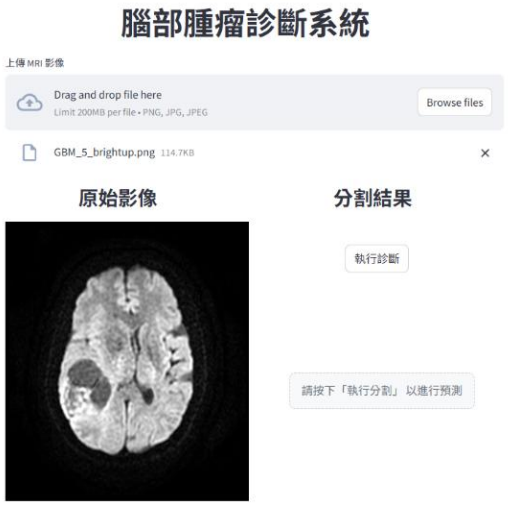


圖 4.2 GUI 介面影像上傳示意圖

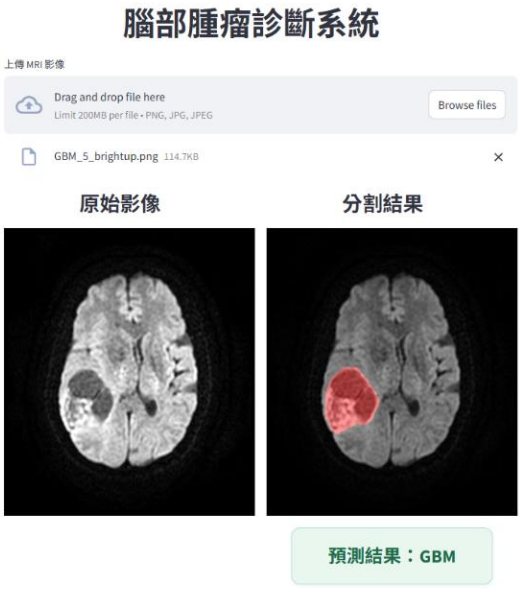


圖 4.3 介面診斷預測結果示意圖

4.7 實驗結果探討

本研究針對腦部 MRI 影像的自動診斷，分別比較了不同架構的分類模型與不同技術類型的分割模型，其實驗結果揭示了模型架構選擇對最終預測表現之影響。

在腦部 MRI 影像分類任務中，不同類型模型架構對最終效能具有顯著影響。整體而言，傳統 CNN 架構（如 ResNet50、ResNeSt50d） 在本研究中表現最為穩定，特別是在增量後資料條件下，ResNet50 達到最高準確率（Accuracy 0.9097），而 ResNeSt50d 則在 Recall（0.7396→0.8891）與 AUC（0.8726→0.9796）皆展現優異表現，顯示其具備優異的特徵識別與泛化能力。純 Transformer 架構（如 ViT、Swin Transformer、EfficientFormer）則在資料量受限情況下學習能力明顯受限，ViT 即便增量後 Precision 僅為 0.5907，F1-score 亦未超過 0.6，呈現模型不穩定與訓練困難的現象。EfficientFormer 雖為設計優化過的輕量 Transformer，但由於缺乏 CNN 提供的空間感知，整體表現仍落後於多數 CNN 架構。PiT（Pooling-based Vision Transformer）作為結合 CNN 式空間降維機制與全域注意力的混合型架構，整體表現略優於純 Transformer，尤其在 Recall（0.7428）與 F1-score（0.7015）具相對平衡性，展現其在有限資料下的應用彈性。

分割任務方面，實例分割模型（YOLOv8、YOLOv11、Mask R-CNN）與語意分割模型（Swin-Unet）雖皆可有效產出腫瘤遮罩，但其在精度與偵測範圍上展現不同技術特性。YOLOv8 明顯為整體表現最佳者，在所有評估指標中皆名列前茅，尤其在 Recall（0.9580）與 Mean-Dice（0.9443）上表現最為優異，顯示其對腫瘤區域涵蓋完整、遮罩準確且邊界清晰。YOLOv11 同樣具備優異遮罩定位能力，整體精準度與 YOLOv8 接近。相較之下，語意分割模型 Swin-Unet 的 Recall（0.9170）略低於 YOLO 模型，且在多數視覺化結果中出現遮罩延展或內部不連續現象，推測其對邊界控制的細緻度略顯不足。但在 Mean-IoU（0.8985）與 Dice（0.9415）指標上仍具備強勁整體區域擷取能力，說明其在結構清晰的腫瘤影像上仍能有效擷取主要病灶區。至於 Mask R-CNN，雖具實例分割能力，然在本研究情境下腫瘤多為單一區塊，其分離性未被充分發揮，導致在 Recall 與 IoU 表現相對較低，遮罩亦易出現破碎與誤判。

整體而言，實例分割架構中的 YOLOv8 在精確性與涵蓋性間取得最佳平衡，適合即時醫學影像應用；而語意分割模型 Swin-Unet 在一定條件下仍保有可觀遮罩品質。模型選擇應依應用情境中的資料特性與需求作彈性調整。

第 5 章　結論與未來展望

5.1 結論

本研究建構了一套結合多模態影像與集成深度學習架構的腦部腫瘤自動化診斷流程，針對分類與分割兩大任務進行全面性分析與效能驗證。

在影像分類任務方面，本研究比較多種 CNN 與 Transformer 架構模型的表現，結果顯示傳統 CNN 模型仍具備優異且穩定的特徵學習能力。其中，ResNet50 在資料經增量處理後達到最高準確率與 F1-score，而 ResNeSt50d 則在召回率與 AUC 表現最為突出，顯示殘差學習與注意力機制對於提升分類精度具有顯著助益。相較之下，純粹的 Transformer 架構如 Vision Transformer 於小樣本資料條件下學習能力受限，易出現未擬合或判斷不穩定的情形，若能搭配更大量的資料進行訓練，相信模型的表現仍有明顯提升的空間。

為進一步提升分類任務整體效能與穩定性，本研究比較了三種集成學習策略來整合多個表現優異之分類模型。實驗結果指出，Stacking 方法整體表現最為出色，其在準確率（0.9441）、精確率（0.9496）、召回率（0.9434）與 F1-score（0.9463）等多項指標中皆優於其他方法，顯示透過次級模型整合基礎模型預測結果，能有效捕捉模型間的互補特性。Soft Voting 則在 AUC 指標上表現最佳（0.9941），顯示其透過機率加總方式對於預測信心的評估更具敏感度，亦具備良好應用價值。

在分割任務方面，本研究採用實例分割與語意分割兩大類深度學習方法進行腦部腫瘤區域之遮罩預測，並比較其在不同評估指標上的表現。實驗結果顯示，實例分割架構中的 YOLOv8 表現最為優異，在精確率（0.9920）、召回率（0.9580）、交集聯集比（0.8980）與 Dice 係數（0.9443）皆達到最高分數，能準確擷取腫瘤邊界並產生高品質遮罩。語意分割模型方面，Swin-Unet 對整體腫瘤區域的涵蓋能力表現良好，在 Recall（0.9170）與 Dice（0.9215）指標上具競爭力，但在部分切片中仍有出現遮罩延展或邊界模糊情形，顯示其對局部邊界特徵的控制仍有改善空間。至於 Mask R-CNN 雖具實例分割能力，但在本研究主要處理單一腫瘤區塊的情境下，其分離特性未被充分發揮，導致遮罩破碎與分割誤差的情形較為明顯，整體分割效能相對較低。

綜合本研究結果，本研究所建立的深度學習模型流程能夠有效應用於腦部 MRI 影像的腫瘤分類與區域分割，並在多項評估指標上達到穩定表現。透過結合多模態影像、資料增量與集成學習策略，整體流程具備處理不同腫瘤類型與影像條件的能力。此方法可協助醫師快速判讀腫瘤類別與位置，提升診斷效率，並可應用於臨床診斷流程的輔助工具或醫療影像分析系統的開發。

5.2 未來展望

本研究主要使用單一醫療機構所提供之二維 MRI 影像進行腦部腫瘤的分類與分割任務。未來可進一步強化資料集的完整性，透過結合不同醫療單位的實際臨床影像，納入更多病患的年齡、性別、病灶變異與疾病進程等多樣化條件，以提升模型對真實臨床情境的適應能力與泛化表現。

此外，現階段僅針對單張二維影像進行分析，後續研究可朝向三維結構發展，導入三維卷積神經網路或其他體積資料處理技術，利用完整的空間資訊進行更精細的腫瘤定位與邊界建構。

針對醫學影像標註高度仰賴專業人力的現況，後續可考慮引入半監督學習或自監督學習技術，活用未標註影像進行預訓練或特徵學習，降低人工遮罩的依賴，並提升模型訓練效率與實務推廣可行性。研究亦可延伸至腫瘤分級、預後預測或治療反應分析等任務，結合影像、臨床與病理資料，拓展模型在臨床決策輔助系統中的應用深度與廣度。

最後，隨著邊緣運算技術與行動裝置應用的快速發展，模型的輕量化與部署效率亦成為重要研究方向。未來可進一步設計適用於邊緣端運算的輕量模型架構，並結合知識蒸餾、模型剪枝等技術進行優化，以提升推論效率與系統靈活度，使本研究提出之診斷流程能更容易於臨床實務或行動醫療場景落地應用。

參考文獻

[1] M. Mir *et al.*, "Detection and isolation of brain tumors in cancer patients using neural network techniques in MRI images," *Scientific Reports,* vol. 14, no. 1, p. 23341, 2024/10/07 2024, doi: 10.1038/s41598-024-68567-5.

[2] A. Castellano *et al.*, "Advanced Imaging Techniques for Radiotherapy Planning of Gliomas," *Cancers*, vol. 13, no. 5, doi: 10.3390/cancers13051063.

[3] (2024). *民國 111 年癌症登記年報*. [Online] Available: https://www.hpa.gov.tw/Pages/List.aspx?nodeid=269

[4] S. Central Brain Tumor Registry of the United, "CBTRUS Fact Sheet," 2024// 2024. [Online]. Available: https://cbtrus.org/cbtrus-fact-sheet/.

[5] Y. Liu, F. Zhou, H. Ali, J. D. Lathia, and P. Chen, "Immunotherapy for glioblastoma: current state, challenges, and future perspectives," *Cellular & Molecular Immunology,* vol. 21, no. 12, pp. 1354–1375, 2024/12/01 2024, doi: 10.1038/s41423-024-01226-x.

[6] T.-W. Wang *et al.*, "Performance of Convolutional Neural Network Models in Meningioma Segmentation in Magnetic Resonance Imaging: A Systematic Review and Meta-Analysis," *Neuroinformatics,* vol. 23, no. 1, p. 14, 2024/12/28 2024, doi: 10.1007/s12021-024-09704-3.

[7] M. T. M. Wang, J. A. Meyer, and H. V. Danesh-Meyer, "Neuro-ophthalmic evaluation and management of pituitary disease," *Eye,* vol. 38, no. 12, pp. 2279–2288, 2024/08/01 2024, doi: 10.1038/s41433-024-03187-x.

[8] M. Martucci *et al.*, "Magnetic Resonance Imaging of Primary Adult Brain Tumors: State of the Art and Future Perspectives," *Biomedicines,* vol. 11, no. 2, p. 364, 2023. [Online]. Available: https://www.mdpi.com/2227-9059/11/2/364.

[9] E. M. Crowe, W. Alderson, J. Rossiter, and C. Kent, "Expertise Affects Inter-Observer Agreement at Peripheral Locations within a Brain Tumor," (in English), *Frontiers in Psychology,* Original Research vol. Volume 8 - 2017, 2017–September–20 2017, doi: 10.3389/fpsyg.2017.01628.

[10] K. L.-C. Hsieh, R.-J. Tsai, Y.-C. Teng, and C.-M. Lo, "Effect of a computer-aided diagnosis system on radiologists' performance in grading gliomas with MRI," *PLOS ONE,* vol. 12, no. 2, p. e0171342, 2017, doi:

10.1371/journal.pone.0171342.

[11] F. J. Dorfner, J. B. Patel, J. Kalpathy-Cramer, E. R. Gerstner, and C. P. Bridge, "A review of deep learning for brain tumor analysis in MRI," *npj Precision Oncology,* vol. 9, no. 1, p. 2, 2025/01/03 2025, doi: 10.1038/s41698-024-00789-2.

[12] M. M. M, M. T. R, V. K. V, and S. Guluwadi, "Enhancing brain tumor detection in MRI images through explainable AI using Grad-CAM with Resnet 50," *BMC Medical Imaging,* vol. 24, no. 1, p. 107, 2024/05/11 2024, doi: 10.1186/s12880-024-01292-7.

[13] S. Sahayam and U. Jayaraman, "Integrating Edges into U-Net Models with Explainable Activation Maps for Brain Tumor Segmentation using MR Images," *arXiv preprint arXiv:2401.01303,* 2024.

[14] C. McNamara *et al.*, "2021 WHO classification of tumours of the central nervous system: a review for the neuroradiologist," *Neuroradiology,* vol. 64, no. 10, pp. 1919–1950, 2022.

[15] N. Rezaei and S. Hanaei, "Human brain and spinal cord tumors: from bench to bedside. Volume 2: the path to bedside management," 2023.

[16] Q. T. Ostrom *et al.*, "CBTRUS Statistical Report: Primary Brain and Other Central Nervous System Tumors Diagnosed in the United States in 2015–2019," *Neuro-Oncology,* vol. 24, no. Supplement_5, pp. v1–v95, 2022, doi: 10.1093/neuonc/noac202.

[17] A. A. D. J. Alruwaili, Orlando, *Meningioma*, S. Publishing, ed., Treasure Island (FL): StatPearls Publishing, 2023. [Online]. Available: https://www.ncbi.nlm.nih.gov/books/NBK560538/. Accessed on: 2025 May 22.

[18] M. Price *et al.*, "CBTRUS Statistical Report: Primary Brain and Other Central Nervous System Tumors Diagnosed in the United States in 2017–2021," *Neuro-Oncology,* vol. 26, no. Supplement_6, pp. vi1–vi85, 2024, doi: 10.1093/neuonc/noae145.

[19] R. Goldbrunner *et al.*, "EANO guideline on the diagnosis and management of meningiomas," *Neuro-Oncology,* vol. 23, no. 11, pp. 1821–1834, 2021, doi: 10.1093/neuonc/noab150.

[20] J. Watts, G. Box, A. Galvin, P. Brotchie, N. Trost, and T. Sutherland, "Magnetic resonance imaging of meningiomas: a pictorial review," *Insights into imaging,*

vol. 5, pp. 113–122, 2014.

[21] S. A. Russ, Catherine; Shafiq, Ismat, *Pituitary Adenoma*, Treasure Island (FL): StatPearls Publishing, 2023. [Online]. Available: https://www.ncbi.nlm.nih.gov/books/NBK554451/. Accessed on: May 23, 2025.

[22] V. A. Gerriets, Jordan; Nappe, Thomas M., *Physiology, Pituitary Hormones*, S. Publishing, ed., 2021 ed. Treasure Island (FL): StatPearls Publishing, 2021. [Online]. Available: https://www.ncbi.nlm.nih.gov/books/NBK557556/. Accessed on: 2025 May 23.

[23] S. Petersenn *et al.*, "Diagnosis and management of prolactin-secreting pituitary adenomas: a Pituitary Society international Consensus Statement," *Nature Reviews Endocrinology,* vol. 19, no. 12, pp. 722–740, 2023.

[24] E. Whyte, M. Nezu, C. Chik, and T. Tateno, "Update on current evidence for the diagnosis and management of nonfunctioning pituitary neuroendocrine tumors," *Endocrinology and Metabolism,* vol. 38, no. 6, pp. 631–654, 2023.

[25] Y. Pang *et al.*, "Visual Pathway Recovery Post Pituitary Adenoma Surgery: Insights from Retinal Structure, Vascular Density, and Neural Conduction Analysis," *Ophthalmology and Therapy,* vol. 13, no. 7, pp. 1993–2008, 2024.

[26] P. U. Freda *et al.*, "Pituitary Incidentaloma: An Endocrine Society Clinical Practice Guideline," *The Journal of Clinical Endocrinology & Metabolism,* vol. 96, no. 4, pp. 894–904, 2011, doi: 10.1210/jc.2010-1048.

[27] J. A. Mann, Y. Starreveld, J. Riva-Cambrin, and K. Lithgow, "A Narrative Review of Surgery for Prolactinomas: Considerations and Controversies," *Journal of Clinical Medicine,* vol. 14, no. 4, p. 1089, 2025.

[28] A. Shaaban *et al.*, "Long-term radiographic and endocrinological outcomes of stereotactic radiosurgery for recurrent or residual nonfunctioning pituitary adenomas," *Journal of neurosurgery,* vol. 1, no. aop, pp. 1–8, 2024.

[29] Q. T. Ostrom, G. Cioffi, K. Waite, C. Kruchko, and J. S. Barnholtz-Sloan, "CBTRUS Statistical Report: Primary Brain and Other Central Nervous System Tumors Diagnosed in the United States in 2014–2018," *Neuro-Oncology,* vol. 23, no. Supplement_3, pp. iii1–iii105, 2021, doi: 10.1093/neuonc/noab200.

[30] D. N. Louis *et al.*, "The 2021 WHO Classification of Tumors of the Central Nervous System: a summary," *Neuro-Oncology,* vol. 23, no. 8, pp. 1231–1251,

2021, doi: 10.1093/neuonc/noab106.

[31] P. Y. Wen and S. Kesari, "Malignant gliomas in adults," *New England Journal of Medicine,* vol. 359, no. 5, pp. 492–507, 2008.

[32] P. Vollmuth, P. Karschnia, F. Sahm, Y. W. Park, S. S. Ahn, and R. Jain, "A Radiologist's Guide to IDH-Wildtype Glioblastoma for Efficient Communication With Clinicians: Part I-Essential Information on Preoperative and Immediate Postoperative Imaging," *Korean journal of radiology,* vol. 26, no. 3, p. 246, 2025.

[33] M. Law *et al.*, "Glioma grading: sensitivity, specificity, and predictive values of perfusion MR imaging and proton MR spectroscopic imaging compared with conventional MR imaging," *American journal of neuroradiology,* vol. 24, no. 10, pp. 1989–1998, 2003.

[34] J. Berberat, R. Grobholz, L. Boxheimer, S. Rogers, L. Remonda, and U. Roelcke, "Differentiation between calcification and hemorrhage in brain tumors using susceptibility-weighted imaging: a pilot study," *American Journal of Roentgenology,* vol. 202, no. 4, pp. 847–850, 2014.

[35] R. Stupp *et al.*, "Radiotherapy plus concomitant and adjuvant temozolomide for glioblastoma," *New England journal of medicine,* vol. 352, no. 10, pp. 987–996, 2005.

[36] K. L. Chaichana *et al.*, "Surgical outcomes for older patients with glioblastoma multiforme: preoperative factors associated with decreased survival," *Journal of neurosurgery,* vol. 114, no. 3, pp. 587–594, 2011.

[37] J. E. Villanueva-Meyer, M. C. Mabray, and S. Cha, "Current clinical brain tumor imaging," *Neurosurgery,* vol. 81, no. 3, pp. 397–415, 2017.

[38] B. Stall *et al.*, "Comparison of T2 and FLAIR imaging for target delineation in high grade gliomas," *Radiation Oncology,* vol. 5, pp. 1–7, 2010.

[39] A. Romano *et al.*, "Diffusion weighted imaging in neuro-oncology: diagnosis, post-treatment changes, and advanced sequences—an updated review," *Cancers,* vol. 15, no. 3, p. 618, 2023.

[40] T. Tsukamoto and Y. Miki, "Imaging of pituitary tumors: an update with the 5th WHO Classifications—part 1. Pituitary neuroendocrine tumor (PitNET)/pituitary adenoma," *Japanese Journal of Radiology,* vol. 41, no. 8, pp. 789–806, 2023.

[41] A. Korbecki *et al.*, "Role of diffusion-weighted imaging in the diagnosis of pituitary region tumors," *Neuroradiology,* pp. 1–11, 2024.

[42] C. Toh and M. Castillo, "Early-Stage Glioblastomas: MR Imaging–Based Classification and Imaging Evidence of Progressive Growth," *American Journal of Neuroradiology,* vol. 38, no. 2, pp. 288–293, 2017.

[43] T. L. Min, J. W. Allen, J. E. Velazquez Vega, S. G. Neill, and B. D. Weinberg, "MRI imaging characteristics of glioblastoma with concurrent gain of chromosomes 19 and 20," *Tomography,* vol. 7, no. 2, pp. 228–237, 2021.

[44] G. Litjens *et al.*, "A survey on deep learning in medical image analysis," *Medical image analysis,* vol. 42, pp. 60–88, 2017.

[45] Z. Akkus, A. Galimzianova, A. Hoogi, D. L. Rubin, and B. J. Erickson, "Deep Learning for Brain MRI Segmentation: State of the Art and Future Directions," *Journal of Digital Imaging,* vol. 30, no. 4, pp. 449–459, 2017/08/01 2017, doi: 10.1007/s10278-017-9983-4.

[46] K. Fukushima, "Neocognitron: A self-organizing neural network model for a mechanism of pattern recognition unaffected by shift in position," *Biological Cybernetics,* vol. 36, no. 4, pp. 193–202, 1980/04/01 1980, doi: 10.1007/BF00344251.

[47] Y. Lecun, L. Bottou, Y. Bengio, and P. Haffner, "Gradient-based learning applied to document recognition," *Proceedings of the IEEE,* vol. 86, no. 11, pp. 2278–2324, 1998, doi: 10.1109/5.726791.

[48] S. Deepak and P. M. Ameer, "Brain tumor classification using deep CNN features via transfer learning," *Computers in Biology and Medicine,* vol. 111, p. 103345, 2019/08/01/ 2019, doi: https://doi.org/10.1016/j.compbiomed.2019.103345.

[49] M. Sajjad, S. Khan, K. Muhammad, W. Wu, A. Ullah, and S. W. Baik, "Multi-grade brain tumor classification using deep CNN with extensive data augmentation," *Journal of Computational Science,* vol. 30, pp. 174–182, 2019/01/01/ 2019, doi: https://doi.org/10.1016/j.jocs.2018.12.003.

[50] B. Babu Vimala, S. Srinivasan, S. K. Mathivanan, Mahalakshmi, P. Jayagopal, and G. T. Dalu, "Detection and classification of brain tumor using hybrid deep learning models," *Scientific reports,* vol. 13, no. 1, p. 23029, 2023.

[51] M. Jafari *et al.*, "Automatic diagnosis of myocarditis disease in cardiac MRI

modality using deep transformers and explainable artificial intelligence," *arXiv preprint arXiv:2210.14611,* 2022.

[52] A. Vaswani *et al.*, "Attention is all you need," *Advances in neural information processing systems,* vol. 30, 2017.

[53] A. Dosovitskiy *et al.*, "An image is worth 16x16 words: Transformers for image recognition at scale," *arXiv preprint arXiv:2010.11929,* 2020.

[54] Z. Liu *et al.*, "Swin transformer: Hierarchical vision transformer using shifted windows," in *Proceedings of the IEEE/CVF international conference on computer vision*, 2021, pp. 10012–10022.

[55] W. Wang *et al.*, "Pyramid vision transformer: A versatile backbone for dense prediction without convolutions," in *Proceedings of the IEEE/CVF international conference on computer vision*, 2021, pp. 568–578.

[56] P. A. Meshram, S. Joshi, and D. Mahajan, "Brain tumor detection using Swin transformers," *arXiv preprint arXiv:2305.06025,* 2023.

[57] M. M. Ahmed *et al.*, "Brain tumor detection and classification in MRI using hybrid ViT and GRU model with explainable AI in Southern Bangladesh," *Scientific Reports,* vol. 14, no. 1, p. 22797, 2024/10/01 2024, doi: 10.1038/s41598-024-71893-3.

[58] M. S. I. Sajol and A. S. M. J. Hasan, "Benchmarking CNN and Cutting-Edge Transformer Models for Brain Tumor Classification Through Transfer Learning," in *2024 IEEE 12th International Conference on Intelligent Systems (IS)*, 29–31 Aug. 2024 2024, pp. 1–6, doi: 10.1109/IS61756.2024.10705175.

[59] Z. Dai, H. Liu, Q. V. Le, and M. Tan, "Coatnet: Marrying convolution and attention for all data sizes," *Advances in neural information processing systems,* vol. 34, pp. 3965–3977, 2021.

[60] Z. Peng *et al.*, "Conformer: Local features coupling global representations for visual recognition," in *Proceedings of the IEEE/CVF international conference on computer vision*, 2021, pp. 367–376.

[61] S. Mehta and M. Rastegari, "Mobilevit: light-weight, general-purpose, and mobile-friendly vision transformer," *arXiv preprint arXiv:2110.02178,* 2021.

[62] S. Roy *et al.*, "Fibonacci-Net: A Lightweight CNN model for Automatic Brain

Tumor Classification," *arXiv preprint arXiv:2503.13928,* 2025.

[63] P. Zheng, X. Zhu, and W. Guo, "Brain tumour segmentation based on an improved U-Net," *BMC Medical Imaging,* vol. 22, no. 1, p. 199, 2022/11/18 2022, doi: 10.1186/s12880-022-00931-1.

[64] H. Yu *et al.*, "Methods and datasets on semantic segmentation: A review," *Neurocomputing,* vol. 304, pp. 82–103, 2018.

[65] Z. Liu *et al.*, "Deep learning based brain tumor segmentation: a survey," *Complex & Intelligent Systems,* vol. 9, no. 1, pp. 1001–1026, 2023/02/01 2023, doi: 10.1007/s40747-022-00815-5.

[66] Z. U. Abidin, R. A. Naqvi, A. Haider, H. S. Kim, D. Jeong, and S. W. Lee, "Recent deep learning-based brain tumor segmentation models using multi-modality magnetic resonance imaging: A prospective survey," *Frontiers in Bioengineering and Biotechnology,* vol. 12, p. 1392807, 2024.

[67] M. F. Ahamed *et al.*, "A review on brain tumor segmentation based on deep learning methods with federated learning techniques," *Computerized Medical Imaging and Graphics,* vol. 110, p. 102313, 2023/12/01/ 2023, doi: https://doi.org/10.1016/j.compmedimag.2023.102313.

[68] Z. Liao, H. Peng, and T. Liu, "Brain Tumor Segmentation Based on Improved Swin-UNet," in *2023 2nd International Conference on Artificial Intelligence and Intelligent Information Processing (AIIIP)*, 27–29 Oct. 2023 2023, pp. 222–225, doi: 10.1109/AIIIP61647.2023.00048.

[69] K. He, G. Gkioxari, P. Dollár, and R. Girshick, "Mask R-CNN," in *2017 IEEE International Conference on Computer Vision (ICCV)*, 22–29 Oct. 2017 2017, pp. 2980–2988, doi: 10.1109/ICCV.2017.322.

[70] M. G. Ragab, K. U. Danyaro, S. J. Abdulkadir, S. M. Al-Selwi, E. H. Sumiea, and A. Alqushaibi, "Brain Tumor Detection Instance Segmentation Using YOLOv8 in Medical Imaging," in *2024 IEEE Asia-Pacific Conference on Applied Electromagnetics (APACE)*, 21–23 Dec. 2024 2024, pp. 55–58, doi: 10.1109/APACE62360.2024.10877358.

[71] J. Yuan, "Brain tumor image segmentation method using hybrid attention module and improved mask RCNN," *Scientific Reports,* vol. 14, no. 1, p. 20615, 2024/09/04 2024, doi: 10.1038/s41598-024-71250-4.

[72] C. Pitarch, G. Ungan, M. Julià-Sapé, and A. Vellido, "Advances in the use of deep learning for the analysis of magnetic resonance image in neuro-oncology," *Cancers,* vol. 16, no. 2, p. 300, 2024.

[73] K. He, X. Zhang, S. Ren, and J. Sun, "Deep residual learning for image recognition," in *Proceedings of the IEEE conference on computer vision and pattern recognition*, 2016, pp. 770–778.

[74] M. Tan and Q. Le, "Efficientnet: Rethinking model scaling for convolutional neural networks," in *International conference on machine learning*, 2019: PMLR, pp. 6105–6114.

[75] T. Ahmed and N. H. N. Sabab, "Classification and understanding of cloud structures via satellite images with EfficientUNet," *SN Computer Science,* vol. 3, no. 1, p. 99, 2022.

[76] H. Zhang *et al.*, "ResNeSt: Split-Attention Networks," in *2022 IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops (CVPRW)*, 19–20 June 2022 2022, pp. 2735–2745, doi: 10.1109/CVPRW56347.2022.00309.

[77] Z. Liu *et al.*, "Swin transformer v2: Scaling up capacity and resolution," in *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, 2022, pp. 12009–12019.

[78] Y. Li *et al.*, "Efficientformer: Vision transformers at mobilenet speed," *Advances in Neural Information Processing Systems,* vol. 35, pp. 12934–12949, 2022.

[79] B. Heo, S. Yun, D. Han, S. Chun, J. Choe, and S. J. Oh, "Rethinking spatial dimensions of vision transformers," in *Proceedings of the IEEE/CVF international conference on computer vision*, 2021, pp. 11936–11945.

[80] L. Lam and C. Y. Suen, "Application of majority voting to pattern recognition: an analysis of its behavior and performance," *IEEE Trans. Syst. Man Cybern. Part A,* vol. 27, pp. 553–568, 1997.

[81] L. I. Kuncheva, *Combining Pattern Classifiers: Methods and Algorithms*. Hoboken, NJ: Wiley-IEEE Press, 2014.

[82] D. Wolpert, "Stacked Generalization," *Neural Networks,* vol. 5, pp. 241–259, 12/31 1992, doi: 10.1016/S0893-6080(05)80023-1.

[83] J. Long, E. Shelhamer, and T. Darrell, "Fully convolutional networks for semantic

segmentation," in *Proceedings of the IEEE conference on computer vision and pattern recognition*, 2015, pp. 3431–3440.

[84] O. Ronneberger, P. Fischer, and T. Brox, "U-net: Convolutional networks for biomedical image segmentation," in *Medical image computing and computer-assisted intervention–MICCAI 2015: 18th international conference, Munich, Germany, October 5-9, 2015, proceedings, part III 18*, 2015: Springer, pp. 234–241.

[85] S. Minaee, Y. Boykov, F. Porikli, A. Plaza, N. Kehtarnavaz, and D. Terzopoulos, "Image segmentation using deep learning: A survey," *IEEE transactions on pattern analysis and machine intelligence,* vol. 44, no. 7, pp. 3523–3542, 2021.

[86] J. Chen *et al.*, "Transunet: Transformers make strong encoders for medical image segmentation," *arXiv preprint arXiv:2102.04306,* 2021.

[87] H. Cao *et al.*, "Swin-unet: Unet-like pure transformer for medical image segmentation," in *European conference on computer vision*, 2022: Springer, pp. 205–218.

[88] J. Redmon, S. Divvala, R. Girshick, and A. Farhadi, "You only look once: Unified, real-time object detection," in *Proceedings of the IEEE conference on computer vision and pattern recognition*, 2016, pp. 779–788.

[89] Ultralytics. "Ultralytics YOLOv8 Documentation." https://docs.ultralytics.com (accessed.

[90] Ultralytics. "Ultralytics YOLOv11 Documentation."https://docs.ultralytics.com/models/yolo11/ (accessed.

[91] P. Hidayatullah, N. Syakrani, M. R. Sholahuddin, T. Gelar, and R. Tubagus, "YOLOv8 to YOLO11: A Comprehensive Architecture In-depth Comparative Review," *arXiv preprint arXiv:2501.13400,* 2025.

[92] H. Schwertfeger. "Digging into Detectron2." Medium. https://medium.com/@hirotoschwert/digging-into-detectron-2-47b2e794fabd (accessed.

[93] V. W. J. Pelt, S. Gerrets, R. Simões, P. Elkhuizen, and T. Janssen, "Evaluation of delineating the target volume by radiation therapists in breast cancer patients," *Technical Innovations & Patient Support in Radiation Oncology,* vol. 17, pp. 78–81, 03/01 2021, doi: 10.1016/j.tipsro.2021.01.001.